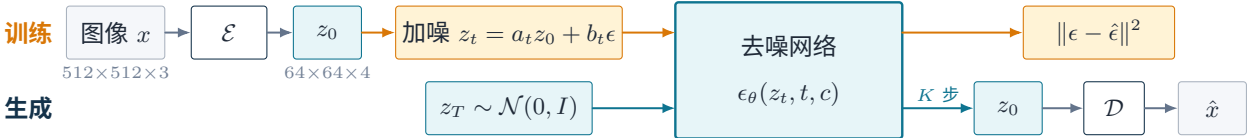
训练
图像 x
512×512×3
$\mathcal{E}$
z_0
64×64×4
加噪 $z_t = a_t z_0 + b_t \epsilon$
去噪网络
$\epsilon_\theta(z_t, t, c)$
$\|\epsilon - \hat{\epsilon}\|^2$
生成
$z_T \sim \mathcal{N}(0, I)$
K 步
z_0
$\mathcal{D}$
$\hat{x}$

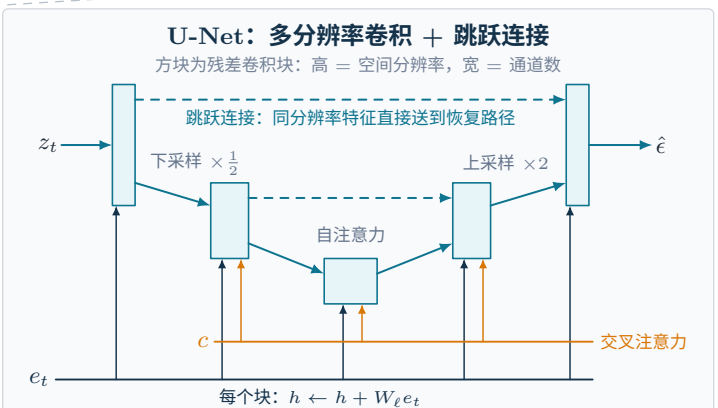
U-Net：多分辨率卷积 + 跳跃连接
方块为残差卷积块：高 = 空间分辨率，宽 = 通道数
跳跃连接：同分辨率特征直接送到恢复路径
z_t
下采样 $\times\frac{1}{2}$
上采样 $\times 2$
$\hat{\epsilon}$
自注意力
c
交叉注意力
e_t
每个块：$h \leftarrow h + W_\ell e_t$

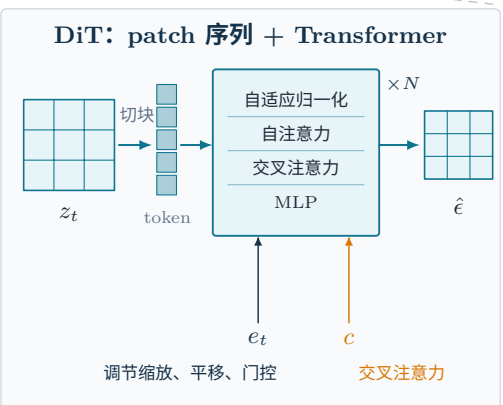
DiT：patch 序列 + Transformer
切块
z_t
token
自适应归一化
自注意力
交叉注意力
MLP
$\times N$
$\hat{\epsilon}$
e_t
c
调节缩放、平移、门控
交叉注意力