生成模型与概率统计

第一讲　生成模型要解决什么问题

张士欣

中国科学院物理研究所　2026.10

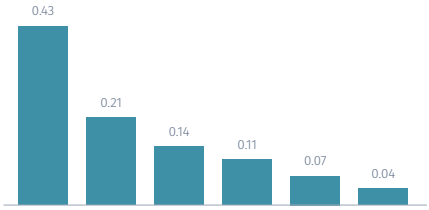
github.com/refraction-ray/free-energy-to-llms



生成式 AI 每天在做什么

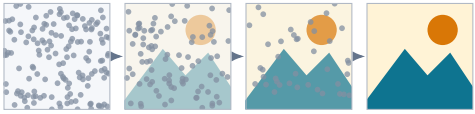
今天天气很 __

提示词 $x_{<t}$



下一个 token 的条件分布 $p_\theta(x_t \mid x_{<t})$

抽一个 token，接到末尾，再算下一个分布



$t = T$ $t = 0$

纯噪声 ⟶ 逐步去噪 ⟶ 图像

每一步都从一个条件分布中抽样

要点

文本续写和图像生成看起来不同，做的是同一件事：先用数据学出一个高维概率分布，再从中抽样。本课讨论这件事在数学上怎样实现。

本课的问题

给定来自未知分布的样本

$$x^{(1)}, \dots, x^{(N)} \sim p_{\text{data}},$$

找一个模型 $p_\theta \approx p_{\text{data}}$，并回答三个问题：

- **表示**：用什么函数族写出 p_θ？
- **学习**：用什么目标衡量 p_θ 与 p_{data} 的差距？
- **采样**：怎样从 p_θ 中抽出新的 x？

条件版本 $p_\theta(x \mid c)$ 中，c 可以是文字描述、目标性质或提示词。

对象	x 的形式
图像	$256 \times 256 \times 3 \approx 2 \times 10^5$ 维连续向量
文本	长度 T 的 token 序列，词表约 10^5
分子	原子种类与 $3N$ 个坐标
自旋	$\{\pm 1\}^N$ 上的构型

难点　维度极高；数据集中在复杂的低维结构附近；只能看到有限样本。

三讲路线

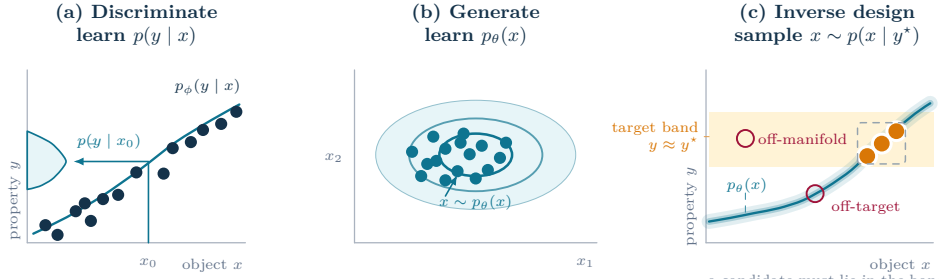
第一讲	**生成模型要解决什么问题**	判别、生成与逆向设计；神经网络；怎样比较两个分布；玻尔兹曼分布与自由能；生成模型地图
第二讲	**处理 $p(x)$ 的五种方式**	自回归、Normalizing Flow、VAE、GAN、能量模型与 MCMC
第三讲	**从去噪到大模型**	扩散、score 与 Flow Matching；Transformer；大模型的训练阶段

每个模型都回答四个问题

概率对象	密度、条件概率、能量，还是密度的梯度？	训练目标	优化哪个散度或下界？
采样方式	一次前向、逐步生成、解微分方程，还是马尔可夫链？	代价	成本与失效模式在哪里？

判别、生成与逆向设计

同一批对象，三种问题



条件概率　判别模型学 $p(y \mid x)$：给定对象预测性质。生成模型学 $p(x)$：哪些对象本身合理。逆向设计要的是 $p(x \mid y)$：满足目标性质、又仍然合理的对象。

生成模型要提供的两种基本能力

采样 $x \sim p_\theta$

生成新图像、新分子
续写一段文本
为蒙特卡洛提供样本

评估密度 $p_\theta(x)$

判断一个样本是否合理
异常检测、模型比较
重要性重加权

条件化：把 c 作为输入，两种能力都有条件版本 $p_\theta(x \mid c)$。
逆向设计、文生图、按提示词回答都属于这一类。

要点

很少有模型能同时廉价地做好这两件事：GAN 采样快但给不出密度；能量模型的密度写法最灵活，采样却很慢；自回归模型两者兼有，代价是只能逐个生成。第二讲的各类模型就是在这里做不同的取舍。

逆向设计：先验乘以似然

$$p(x \mid y^\star) = \frac{p_\phi(y^\star \mid x)\, p_\theta(x)}{p(y^\star)}$$

先验 $p_\theta(x)$ — 生成模型：这个 x 像不像真实数据？

似然 $p_\phi(y^\star \mid x)$ — 性质预测器：这个 x 达到目标 $y^\star$ 了吗？

分母 $p(y^\star)$ — 与 x 无关，只负责让总概率为 1

先验 $p_\theta(x)$

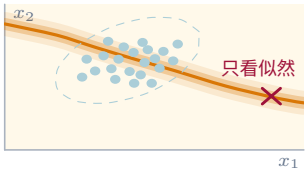
生成模型：哪些设计像真的



×

似然 $p_\phi(y^\star \mid x)$

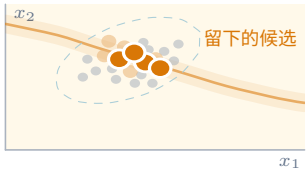
性质预测器：哪些设计达到目标



⇒

后验 $p(x \mid y^\star)$

两个条件同时满足



为什么要乘先验　预测器 p_ϕ 只在训练数据附近可靠。只最大化似然，会找到数据之外、预测器误判的设计（中图 ×）；乘上先验后，留下的候选既达到目标，又像真实数据。

条件分布从哪里来：两条路线

路线 A：先建模，再用贝叶斯公式拼出来

$$p(x \mid y) = \frac{p_\phi(y \mid x)\, p_\theta(x)}{p(y)}, \quad p(y) = \int p_\phi(y \mid x)\, p_\theta(x)\, dx$$

分子对任意 x 都能逐点算；分母 $p(y)$（记作 Z_y）要对所有 x 积分，高维时算不出来。绕开分母：

- **MCMC**：只用两个候选的后验之比，分母约掉
- **变分推断**：用可算的 q 逼近后验，分母只贡献常数

路线 B：直接学习条件分布

$$\max_{\psi} \ \mathbb{E}_{(x,y)} \log p_\psi(x \mid y)$$

- y 作为网络输入：文生图里是文字描述，大语言模型里是提示词
- 网络结构保证归一化，没有分母要算

	路线 A：先验 × 似然	路线 B：直接学 $p_\psi(x \mid y)$
需要的数据	大量无标签的 x，加少量带性质的 (x, y)	大量配对的 (x, y)
换一个目标性质	只换预测器 p_ϕ，先验可复用	重新收集配对数据、重新训练
主要代价	归一化常数 Z_y：推断慢、只能近似	配对数据昂贵

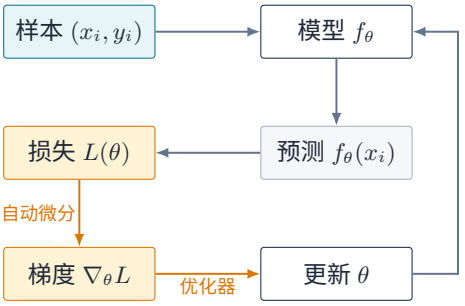
归一化常数 Z 是贯穿全课的难点，后面每个模型都要说明它怎样处理 Z。

神经网络：一族可学习的函数

为什么需要神经网络

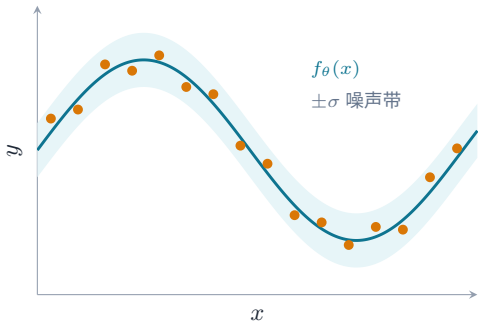
生成模型要表示的都是高维函数：条件概率 $p(y \mid x)$、decoder $p(x \mid z)$、能量 $E(x)$、score $\nabla_x \log p(x)$……

- 高维空间无法查表
- 需要一族参数化函数 f_θ：足够灵活，又能用梯度高效地调整参数 θ
- 神经网络满足这两点；参数可多达 10^9–10^{12}



训练链：前向得到损失，反向得到梯度，再更新参数

回归：拟合一条曲线



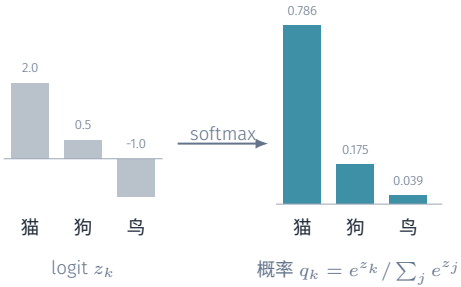
选一个带参数的函数 f_θ，用数据决定参数：

$$L(\theta) = \frac{1}{N}\sum_{i=1}^{N}\big(f_\theta(x_i) - y_i\big)^2$$

训练损失小只说明见过的样本拟合得好；泛化要用测试数据检验。

高斯似然　设 $y = f_\theta(x) + \varepsilon$，$\varepsilon \sim \mathcal{N}(0, \sigma^2)$，则 $-\log p(y \mid x) = (y - f_\theta(x))^2/2\sigma^2 +$ 常数。最小二乘就是这个模型下的极大似然。

分类：网络输出一个分布



真实类别为“猫”：

$$\mathrm{CE} = -\log q_{\text{猫}} = -\log 0.786 \approx 0.24$$

要点

网络输出的是一个分布的参数。VAE 的 decoder、语言模型的输出层都沿用这个思路。

logit $z = f_\theta(x)$ 是网络最后一层的实数输出。

二分类（logistic / sigmoid）

$$q = P(y = 1 \mid x) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

损失：$\ell = -y \log q - (1 - y) \log(1 - q)$，$y \in \{0, 1\}$

K 分类（softmax）

$$q_k = P(y = k \mid x) = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}$$

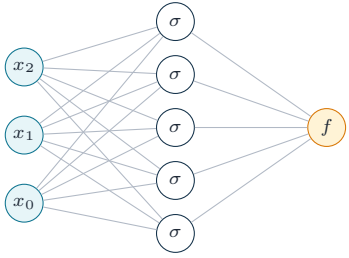
损失：$\ell = -\log q_y$，只取真实类别那一项

σ 是 $K = 2$ 时的 softmax（logit 取 $(z, 0)$）。两种损失都叫交叉熵，分别是 Bernoulli 与 categorical 分布的负对数似然。

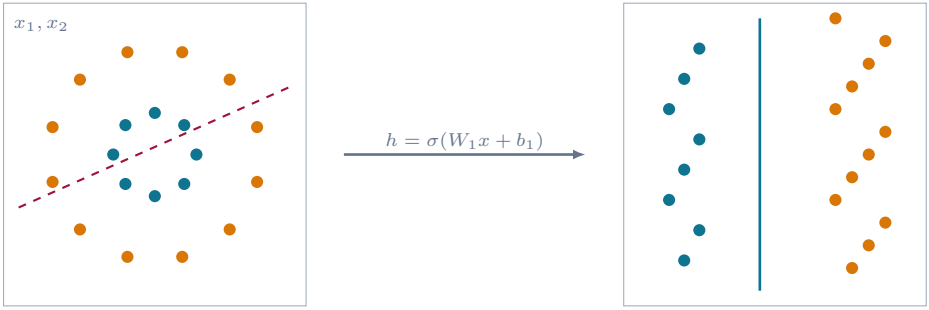
多层感知机

$$f_\theta(x) = W_2\,\sigma(W_1 x + b_1) + b_2$$

- 矩阵乘法混合输入的各个分量
- 逐元素的非线性激活 σ 让函数可以弯曲
- 去掉 σ，多层仿射变换仍是一个仿射变换
- 加深网络就是反复组合这两种操作；参数 $\theta = (W_1, b_1, W_2, b_2, \ldots)$ 全部由数据学出



隐藏层在做特征变换



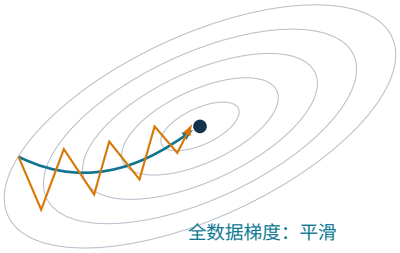
输入空间：没有一条直线能分开

特征空间（横轴 $h_1 \sim \|x\|^2$）：一条直线即可

要点

最后一层只是线性的分类器或回归器；前面各层学到的，是让问题变简单的表示。所需的特征由训练数据和损失共同决定，不需要人工设计。

梯度下降与随机梯度

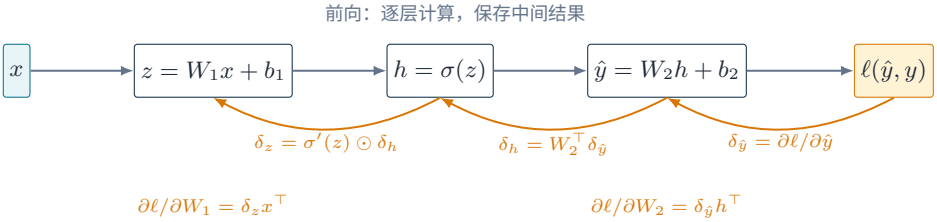


$$\theta_{k+1} = \theta_k - \eta \nabla_\theta L(\theta_k)$$

- η 是学习率；实际常用 Adam 等自适应优化器
- 非凸问题中只保证沿局部下降方向走

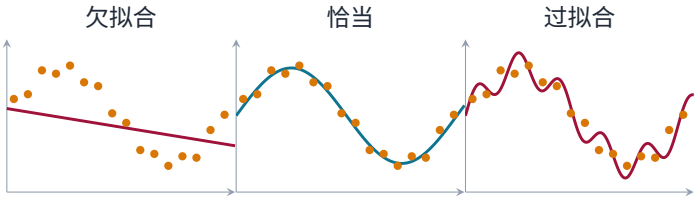
蒙特卡洛估计 $\nabla L = \frac{1}{N}\sum_{i=1}^{N} \nabla \ell_i$ 是对数据分布求期望；每次随机取 B 个样本，$\frac{1}{B}\sum_{i\in\mathcal{B}} \nabla \ell_i$ 是它的无偏估计，方差 $\propto 1/B$。这就是随机梯度下降（SGD）。

反向传播：沿计算图使用链式法则



- 一次反向传播得到对全部参数的梯度，代价只是前向计算的几倍，与参数个数无关
- 自动微分负责算梯度，优化器负责用梯度；两者是训练链中不同的步骤
- 计算图中若有“从分布中抽样”这一步，梯度不能直接穿过，需要专门的估计方法（第二讲）

表达能力与泛化



通用近似定理：单隐藏层网络只要足够宽，就能在紧集上把任意连续函数逼近到任意精度。这是存在性结论：它不保证网络小、数据够、梯度下降能找到参数，也不保证训练区域外的预测正确。

偏差与方差　误差来自三处：函数族不够灵活（近似误差），优化没找到好参数（优化误差），有限样本导致过拟合（估计误差）。

小结：一条训练链

本节要点

1. 损失函数就是在某个选定分布下的负对数似然：MSE 对应高斯，交叉熵对应 categorical
2. 训练就是用小批量样本估计期望梯度，再沿梯度迭代
3. 神经网络是一族灵活、可求梯度的函数，它的输出常常是一个分布的参数

到这里，网络拟合的还是一个数或一个条件分布 $p(y \mid x)$。生成模型要拟合的是整个高维分布 $p(x)$，而我们只有它的样本。

接下来的问题：怎样衡量两个分布的差距？

怎样比较两个分布

从拟合一个数到拟合一个分布

我们有 p_{data} 的样本和模型 p_θ，需要一个“距离” $D(p_{\text{data}}, p_\theta)$：只用样本就能估计；$D = 0$ 当且仅当两分布相同；对 θ 可求梯度。

散度	直观含义	在哪里出现
$\mathrm{KL}(p_{\text{data}} \| p_\theta)$	数据在模型下的平均对数似然	自回归、Flow；VAE 与扩散优化它的上界
$\mathrm{KL}(q \| \pi)$	模型样本在目标下是否合理	变分推断、统计物理、RLHF
$\mathrm{JSD}(p \| q)$	$\frac{1}{2}\mathrm{KL}(p \| m) + \frac{1}{2}\mathrm{KL}(q \| m)$，$m = \frac{1}{2}(p+q)$：分类器能否分辨两组样本	GAN
Fisher 散度	$\frac{1}{2}\mathbb{E}_p \| \nabla_x \log p - \nabla_x \log q \|^2$：两者的 score 是否处处一致	score matching、扩散

要点

选择哪一种散度，就是选择哪一类误差被重视；不同生成模型的行为差异很多来自这里。

KL 散度

$$\mathrm{KL}(p\|q) = \mathbb{E}_{x\sim p}\left[\log \frac{p(x)}{q(x)}\right]$$

- $\mathrm{KL} \geq 0$，等号当且仅当 $p = q$
- 不对称：$\mathrm{KL}(p\|q) \neq \mathrm{KL}(q\|p)$，期望取在哪个分布下，哪里的误差就被重视
- 信息论含义：用为 q 设计的编码去编码来自 p 的样本，平均多付出的信息量

★ 非负性

由 Jensen 不等式（$\log$ 是凹函数）：

$$-\mathrm{KL}(p\|q) = \mathbb{E}_p \log \frac{q}{p} \leq \log \mathbb{E}_p \frac{q}{p} = \log \int q = 0$$

相对熵 KL 是两个分布的对数似然比在 p 下的期望；假设检验中它决定了区分 p 与 q 的错误率衰减速度。

极大似然就是最小化前向 KL

- 数据集 $\{x^{(i)}\}_{i=1}^{N}$ 给出经验分布 $\hat{\pi}$，每个样本权重 $1/N$
- 模型族 p_θ：训练要在其中找一个离 $\hat{\pi}$ 最近的分布

★ 关键一步

$$\mathrm{KL}(\hat{\pi}\|p_\theta) = \mathbb{E}_{\hat{\pi}}[\log \hat{\pi}(x)] - \mathbb{E}_{\hat{\pi}}[\log p_\theta(x)] = \underbrace{\text{常数}}_{\text{与}\theta\text{ 无关}} - \frac{1}{N}\sum_{i=1}^{N} \log p_\theta(x^{(i)})$$

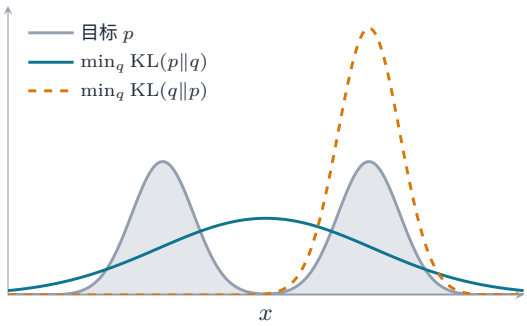
极大似然估计 MLE 是在模型族里找离经验分布最近的分布；前面的 MSE 与交叉熵都是它的特例。

用这个目标训练只需要两样东西：

- 数据样本
- 能逐点计算 $\log p_\theta(x)$

第二条正是“显式密度”模型必须满足的要求。

两个方向，两种行为



用单个高斯 q 拟合双峰目标 p：

- 前向 KL 在 p 下取期望：p 有质量而 $q \approx 0$ 处代价极大，q 只好横跨两峰
- 反向 KL 在 q 下取期望：q 只需留在 p 的高概率区，于是落在一个峰上

> **要点**
>
> 前向 KL 覆盖所有模式，可能把概率放到模式之间；反向 KL 样本锐利，却可能丢掉模式。第二讲比较 VAE、GAN 时会再用到这张图。

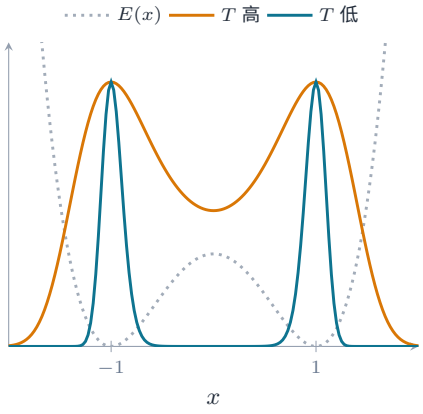
玻尔兹曼分布

统计物理中，温度 T 下构型 x 的概率为

$$\pi(x) = \frac{e^{-E(x)/k_B T}}{Z}, \quad Z = \int e^{-E(x)/k_B T} dx$$

- $E(x)$：能量，越低越可能
- T：温度。$T \to 0$ 时集中到能量最低处；T 很高时趋于均匀
- Z：配分函数，对所有构型求和或积分

难点　采样和归一化都绕不开 Z。



双势阱能量与两个温度下的未归一化密度 $e^{-E/k_B T}$

玻尔兹曼分布从哪里来

★ 最大熵推导

只知道平均能量 $\sum_x p(x)E(x) = U$ 时，求熵最大的分布：

$$\max_p \; -\sum_x p\log p - \alpha\Big(\sum_x p - 1\Big) - \beta\Big(\sum_x pE - U\Big)$$

对 $p(x)$ 求导令其为零：

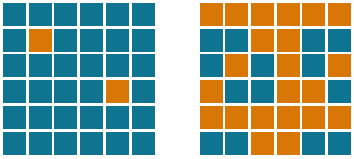
$$-\log p - 1 - \alpha - \beta E(x) = 0,$$

$$p(x) = \frac{e^{-\beta E(x)}}{Z}, \qquad \beta = \frac{1}{k_B T}$$

最大熵原理　在给定约束下最不额外假设的分布；β 是平均能量约束的拉格朗日乘子。

例：Ising 模型　$s_i = \pm 1$，

$$E(s) = -J\sum_{\langle ij\rangle} s_i s_j$$



低温：有序　　高温：无序

$N = 100$ 个自旋就有 $2^{100} \approx 10^{30}$ 个构型，Z 无法逐项求和。

反向 KL 就是变分自由能

目标是玻尔兹曼分布 $\pi = e^{-\beta E}/Z$，用一个可采样、可算密度的分布 q 去逼近它：

★ 关键一步

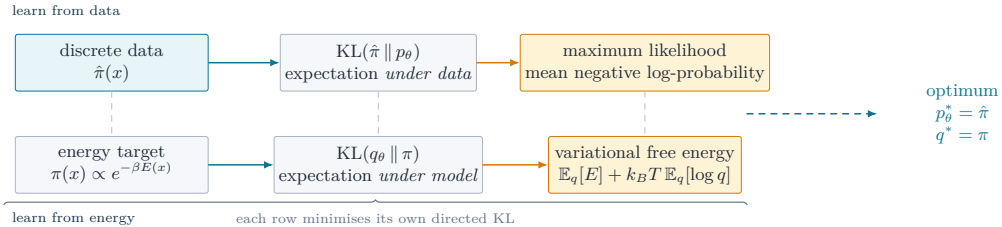
$$\mathrm{KL}(q\|\pi) = \mathbb{E}_q[\log q] + \beta\,\mathbb{E}_q[E] + \log Z = \beta\big(F[q] - F\big) \geq 0,$$

$$F[q] = \underbrace{\mathbb{E}_q[E]}_{\text{平均能量}} - T \underbrace{S[q]}_{-k_B\mathbb{E}_q[\log q]}, \qquad F = -k_B T \log Z$$

- 最小化反向 KL 等价于最小化变分自由能 $F[q]$，下界 F 在 $q = \pi$ 时取到
- 只需从 q 采样并计算 E；不需要 Z，也不需要数据

变分原理　能量项把 q 推向低能构型，熵项阻止 q 塌缩到一点；平衡就是低能与高熵的折中。

两种学习情形



手中有什么	目标	期望在谁下	典型问题
数据样本 $\hat{\pi}$	$\mathrm{KL}(\hat{\pi}\|p_\theta)$：极大似然	数据	生成模型训练（第二、三讲）
能量函数 $E(x)$	$\mathrm{KL}(q\|\pi)$：变分自由能	模型	统计物理采样、变分推断、RLHF（第三讲）

归一化常数：反复出现的难点

同一个积分以不同面目出现：

- 贝叶斯后验中的 Z_y
- 玻尔兹曼分布中的 Z
- 任何写成 $p_\theta = \tilde{p}_\theta / Z_\theta$ 的模型

高维积分既难算，又让采样变难：不知道 Z，就不能直接按概率抽取构型。

处理方式	对应模型
构造上自动归一化	自回归、Flow
优化一个下界	VAE
不需要密度	GAN
只用密度比值	能量模型 + MCMC
只用 $\nabla_x \log p$	score matching、扩散

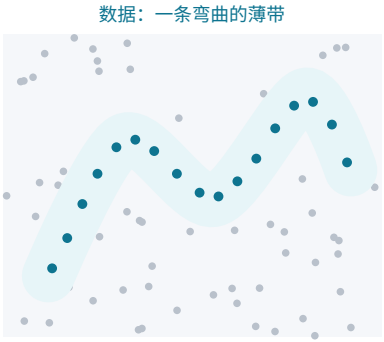
> **要点**
> 各类生成模型的一个主要区别，就是怎样对付 Z。

生成模型地图

高维分布难在哪里

- **维度灾难**：每维分 M 格，直方图需要 M^d 个格子。$M = 10$、$d = 100$ 时是 10^{100}
- **集中在低维结构**：真实图像只占像素空间中极小的一部分，随机像素几乎从不像一张照片
- **只有有限样本**：要从 N 个点推断整个分布，还要能生成没见过的样本

于是需要三样东西：灵活的函数族（神经网络）、只依赖样本的训练目标（如极大似然）、可执行的采样程序。



六条路线

算出 $p(x)$	**分解　自回归** $p(x)=\prod_t p(x_t \mid x_{<t})$ 精确似然；逐个采样，串行 链式法则	**变换　Flow** $x=f_\theta^{-1}(z),\ z\sim\mathcal{N}(0,I)$ 精确似然；可逆结构受限 随机变量的变量替换	**隐变量　VAE** $p(x)=\int p(z)\,p_\theta(x \mid z)\,dz$ 只能优化下界 边缘化、Jensen 不等式
绕开归一化	**对抗　GAN** $x=G_\theta(z)$ 不给密度，只比较样本 两样本检验	**能量　EBM** $p(x)\propto e^{-E_\theta(x)}$ 未归一化；靠马尔可夫链采样 玻尔兹曼分布、MCMC	**去噪　扩散** $s_\theta(x,t)\approx\nabla_x \log p_t(x)$ 学习各噪声水平的 score 高斯卷积、条件期望、SDE

上一行能算出（或界住）$p(x)$，下一行绕开归一化；底部是每条路线借用的概率工具。

第一讲小结

带走的几件事

1. 生成模型学的是整个分布 $p(x)$ 或 $p(x \mid c)$；两种基本能力是采样与密度评估，条件生成是它们的条件版本
2. 神经网络是一族可求梯度的函数，常输出分布的参数；常见损失都是某个分布的负对数似然
3. 极大似然等价于最小化前向 KL；从能量出发的变分自由能等价于最小化反向 KL
4. 两个方向的 KL 行为不同：前向覆盖模式，反向抓住模式
5. 归一化常数 Z 是高维概率建模的核心难点，各类模型的区别就在怎样处理它

下一讲：沿地图依次看自回归、Flow、VAE、GAN 与能量模型怎样处理 $p(x)$。