生成模型与概率统计

第二讲　处理 $p(x)$ 的五种方式

张士欣

中国科学院物理研究所　2026.10

github.com/refraction-ray/free-energy-to-llms



上一讲留下的问题

- 训练目标：极大似然 $=$ 最小化 $\mathrm{KL}(\hat{\pi}\|p_\theta)$，需要能逐点计算 $\log p_\theta(x)$
- 从能量出发：最小化 $\mathrm{KL}(q\|\pi)$，即变分自由能
- 难点：高维分布的归一化常数 Z；不知道 Z，既算不出密度，也不能直接抽样

本讲沿地图依次看五类模型怎样处理 $p(x)$，每一类都回答同样四个问题。

概率对象	密度、条件概率、能量，还是密度的梯度？
训练目标	优化哪个散度或下界？
采样方式	一次前向、逐步生成、微分方程，还是马尔可夫链？
代价与失效	成本与失效模式在哪里？

本讲路线

算出 $p(x)$	**分解　自回归** $p(x) = \prod_t p(x_t \mid x_{<t})$ 精确似然；逐个采样，串行 链式法则	**变换　Flow** $x = f_\theta^{-1}(z),\ z \sim \mathcal{N}(0, I)$ 精确似然；可逆结构受限 随机变量的变量替换	**隐变量　VAE** $p(x) = \int p(z)\, p_\theta(x \mid z)\, dz$ 只能优化下界 边缘化、Jensen 不等式
绕开归一化	**对抗　GAN** $x = G_\theta(z)$ 不给密度，只比较样本 两样本检验	**能量　EBM** $p(x) \propto e^{-E_\theta(x)}$ 未归一化；靠马尔可夫链采样 玻尔兹曼分布、MCMC	**去噪　扩散** $s_\theta(x, t) \approx \nabla_x \log p_t(x)$ 学习各噪声水平的 score 高斯卷积、条件期望、SDE

本讲：自回归、Flow、VAE、GAN、能量模型；扩散留到第三讲。

自回归：把联合分布拆开

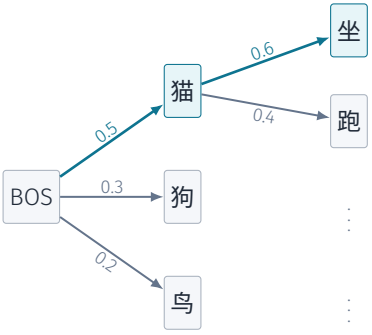
链式法则

对序列 $x = (x_1, \ldots, x_T)$，恒有

$$p(x) = \prod_{t=1}^{T} p(x_t \mid x_{<t})$$

- 直接给每个序列赋概率要 $|\mathcal{V}|^T$ 个数；$|\mathcal{V}| = 10^5$、$T = 1000$ 时是 10^{5000}
- 分解后每一步只需一个 $|\mathcal{V}|$ 类的 categorical 分布，由同一个网络读入前缀给出
- 每个因子都已归一化，乘积自动归一化：$Z = 1$

链式法则　恒等式，不含近似；近似只在用网络表示条件分布这一步。



$p(\text{猫}, \text{坐}) = 0.5 \times 0.6 = 0.3$

顺序同时规定了采样程序：沿树从根走到叶。图像也可以排成序列，从左到右、从上到下逐个生成：早期逐像素；现在多先压成离散 token 网格，一个 token 对应一小块区域。

从极大似然到逐 token 交叉熵

★ 关键一步

把链式分解代入第一讲的 MLE：

$$-\frac{1}{N}\sum_{i}\log p_\theta(x^{(i)}) = -\frac{1}{N}\sum_{i}\sum_{t}\log p_\theta\big(x_t^{(i)} \mid x_{<t}^{(i)}\big) = \frac{1}{N}\sum_{i}\sum_{t}\mathrm{CE}\big(e_{x_t^{(i)}},\, \pi_{\theta,t}\big)$$

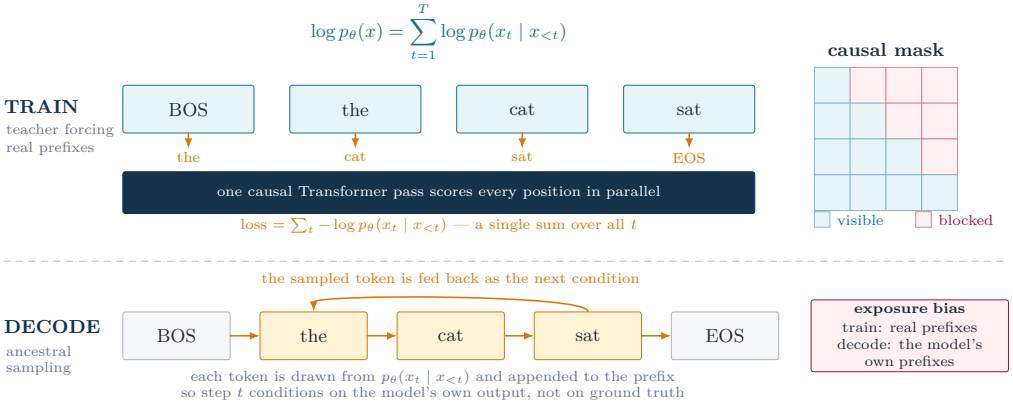
其中 $\pi_{\theta,t}$ 是网络在位置 t 输出的词表分布，e_{x_t} 是真实 token 的 one-hot 向量。

- 每个位置都是一道 $|\mathcal{V}|$ 类的分类题，标签是真实的下一个 token
- 一条序列提供 T 道题，全部无须人工标注

要点

大语言模型的预训练损失，就是这个分解下的极大似然。

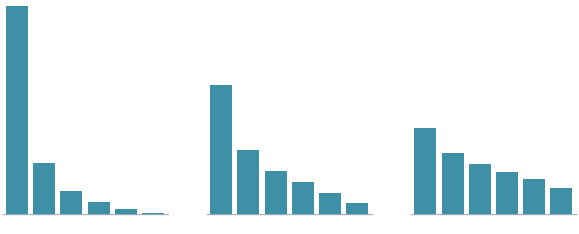
训练并行，生成串行



Teacher forcing：训练时每个位置都读真实前缀；因果 mask 让所有位置在一次前向中并行计算。

Ancestral sampling：生成时抽到的 token 要放回条件里，必须一个一个来。训练见真实前缀、部署见自己的前缀，这个差异叫 exposure bias。

采样温度与截断



同一组 logit（“好、热、冷、不错、晴朗、糟”）在三种温度下的分布

$$p_\tau(v) = \frac{e^{l_v/\tau}}{\sum_u e^{l_u/\tau}}$$

- $\tau < 1$ 更尖，$\tau > 1$ 更平
- top-k / top-p：只保留概率最高的一部分 token，再重新归一化
- 只有 $\tau = 1$ 且不截断时，抽样才严格服从模型自身的分布

玻尔兹曼分布 softmax 就是以 $-l_v$ 为能量、τ 为温度的玻尔兹曼分布。

自回归：小结

概率对象

$p_\theta(x) = \prod_t p_\theta(x_t \mid x_{<t})$
显式、精确归一化

训练目标

逐 token 交叉熵
= 极大似然

采样方式

从左到右逐个抽样
温度、top-k、top-p

代价与失效

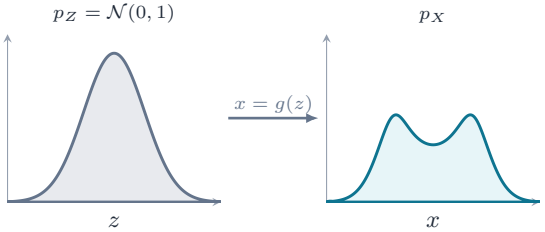
生成串行，延迟随长度增长；exposure bias

要点

自回归是离散序列的首选：似然精确、训练稳定、条件可以随时改变。对连续数据（图像、坐标）没有天然的“下一个”，串行生成也慢，于是需要别的路线。

Normalizing Flow：可逆变换

变量替换：概率质量守恒



$g(z) = z + 0.8\tanh 2z$：中间被拉伸，密度变低；两侧被压缩，密度升高

一维单调变换 $x = g(z)$ 下，小区间里的概率不变：

$$p_X(x)\,|dx| = p_Z(z)\,|dz|$$

$$\Rightarrow\ p_X(x) = p_Z\big(g^{-1}(x)\big)\left|\frac{dg^{-1}}{dx}\right|$$

随机变量函数的密度　这是概率课里的变换公式；Flow 把它当作建模工具：选一个简单的 p_Z，学一个可逆的 g。

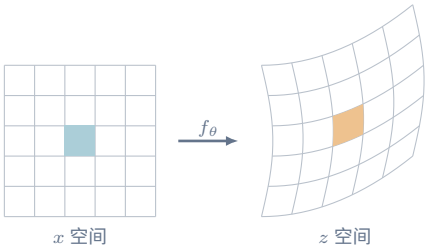
高维：Jacobian 行列式记录体积变化

令 $z = f_\theta(x)$ 可逆可微，

$$\log p_X(x) = \log p_Z\big(f_\theta(x)\big) + \log \left| \det \frac{\partial f_\theta}{\partial x} \right|$$

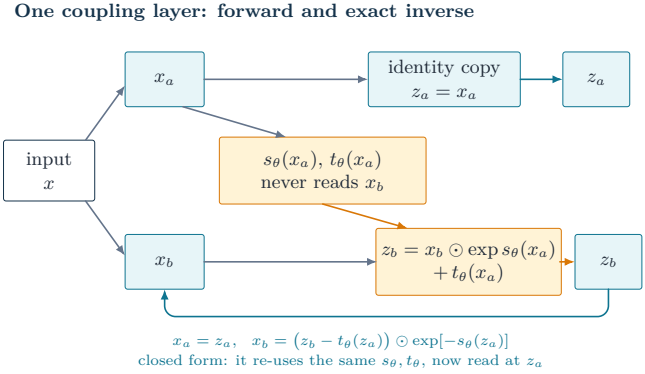
- 训练：极大似然，直接用上式
- 采样：$z \sim \mathcal{N}(0, I)$，再算 $x = f_\theta^{-1}(z)$

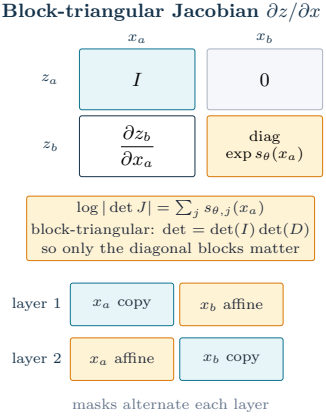
两个障碍　任意网络不一定可逆；$d \times d$ 行列式要 $O(d^3)$，图像的 $d \sim 10^5$。



小方格的面积比 $= |\det J|$

Coupling layer：让 Jacobian 变成三角阵

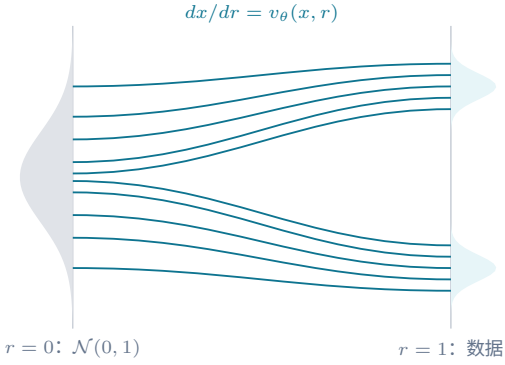




$z_a = x_a$，$z_b = x_b \odot e^{s_\theta(x_a)} + t_\theta(x_a)$。$s_\theta, t_\theta$ 可以是任意网络，它们本身不必可逆。

块三角 Jacobian：$\log|\det J| = \sum_j s_{\theta,j}(x_a)$，代价从 $O(d^3)$ 降到 $O(d)$；相邻层交换 a, b 的划分。

连续极限：沿速度场搬运概率



把 $x_{k+1} = x_k + \Delta r\, v_\theta(x_k, r_k)$ 取 $\Delta r \to 0$：

$$\frac{dx}{dr} = v_\theta(x, r), \qquad \frac{d \log p_r(x_r)}{dr} = -\nabla \cdot v_\theta$$

- 速度网络可以自由设计，不再需要特殊结构
- 代价：极大似然训练时，每个样本都要解一次 ODE、沿轨迹积分散度，再让梯度穿过整个求解过程

连续性方程 $\partial_r p_r + \nabla \cdot (p_r v) = 0$：概率像流体一样被搬运，总量守恒。第三讲的 Flow Matching 保留这个模型，换掉的是训练方式。

Flow：小结

概率对象

可逆映射 $x = f_\theta^{-1}(z)$
变量替换给出精确密度

训练目标

精确负对数似然
$-\log p_Z(f(x)) - \log|\det J|$

采样方式

$z \sim \mathcal{N}(0, I)$ 后运行逆变换
一次前向

代价与失效

可逆性限制网络结构；高维时样本质量常不如扩散

要点

Flow 同时给出精确似然、可逆编码和直接采样，代价是网络必须同维且可逆。如果允许潜变量维度低于数据、映射不可逆，就得放弃精确似然，这就是 VAE。

VAE：隐变量与变分下界

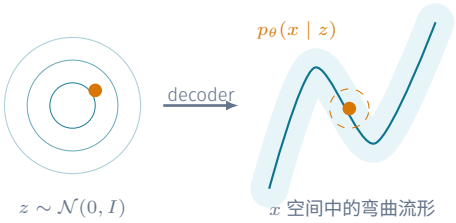
隐变量：观测背后的低维原因

人脸由姿态、光照、表情等少数因素决定。先抽因素，再生成观测：

$$p_\theta(x) = \int p(z)\, p_\theta(x \mid z)\, dz, \quad p(z) = \mathcal{N}(0, I)$$

- decoder 读入 z，输出 $p_\theta(x \mid z)$ 的参数
- 非线性 decoder 下积分没有解析解，后验 $p_\theta(z \mid x)$ 同样难算

边缘化与混合分布　每个 z 给出一个分量 $p_\theta(x \mid z)$，$p_\theta(x)$ 是所有分量按 $p(z)$ 加权的叠加。分量有无穷多个，$\log p_\theta(x)$ 无法逐点算出，下一页用 ELBO 绕开。



一个 z 对应一个小高斯（虚线圈）；所有 z 的小高斯叠在一起，就是浅蓝色的 $p_\theta(x)$

ELBO：把难算的对数似然换成下界

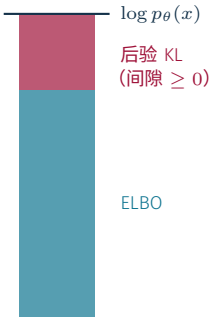
引入 encoder $q_\phi(z \mid x)$ 近似后验：

★ 关键一步

$$\log p_\theta(x) = \underbrace{\mathbb{E}_{q_\phi}\big[\log p_\theta(x \mid z)\big] - \mathrm{KL}\big(q_\phi(z \mid x) \| p(z)\big)}_{\text{ELBO}} + \mathrm{KL}\big(q_\phi(z \mid x) \| p_\theta(z \mid x)\big)$$

把贝叶斯公式 $p_\theta(z \mid x) = p_\theta(x, z)/p_\theta(x)$ 代入最后一项即可验证。

- 第一项：重构，已观测的 x 在 decoder 分布下的对数概率
- 第二项：编码分布不要偏离先验，否则从先验采样会落到没训练过的区域



变分推断　优化 ϕ 让间隙缩小，优化 θ 抬高似然；这正是第一讲的变分推断。

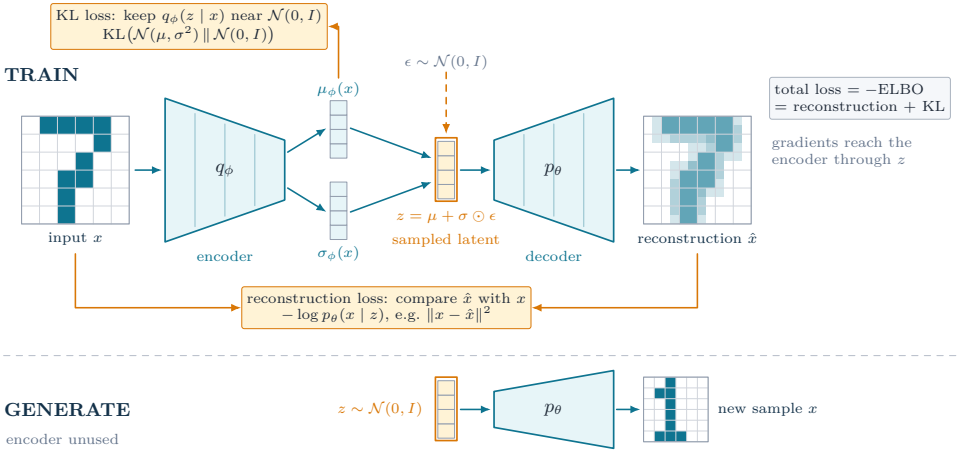
怎样对“抽样”求梯度

ELBO 里有 $\mathbb{E}_{z\sim q_\phi}[\cdot]$，而抽样分布本身含有待训练的 ϕ。两条路径：

	重参数化	score-function
写法	$z=\mu_\phi+\sigma_\phi\odot\epsilon$，$\epsilon\sim\mathcal{N}(0,I)$	$\nabla_\phi\mathbb{E}_{q_\phi}[h]=\mathbb{E}_{q_\phi}\left[h\,\nabla_\phi\log q_\phi(z)\right]$
梯度从哪里来	沿 $\epsilon\to z\to h$ 的计算图回传	用得分 h 加权对数概率的梯度
要求	抽样可写成可微变换	只需 $\log q_\phi$ 可微；z 可以离散
方差	通常较低	通常较高，常减去一个基线
用在哪里	VAE、GAN	强化学习、大模型 RLHF（第三讲）

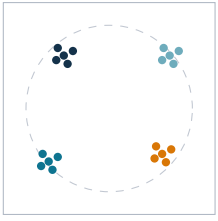
正态随机变量的标准化 $z\sim\mathcal{N}(\mu,\sigma^2)$ 等价于 $z=\mu+\sigma\epsilon$。把随机性挪到与参数无关的 ϵ 上，z 就对 μ,σ 可微。

VAE 的训练与生成

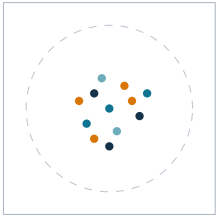


对角高斯时 $\mathrm{KL}(q\|p) = \frac{1}{2}\sum_j(\mu_j^2 + \sigma_j^2 - \log\sigma_j^2 - 1)$ 有解析式；二值数据的重构项是逐位交叉熵，连续数据常用固定方差高斯，即 MSE。

重构与正则的拉锯



KL 权重过小



KL 权重过大

颜色表示不同类别样本的编码；虚线圈是先验 $\mathcal{N}(0, I)$ 的高概率区

- KL 太弱：编码各自聚成小团，团间是空洞；从先验抽到空洞处，decoder 输出不像样
- KL 太强：所有编码都贴着先验，z 不再携带样本信息，即 posterior collapse
- 高斯 decoder 相当于逐像素 MSE，对多种可能取平均，样本偏模糊

VAE：小结

概率对象

潜变量模型 $\int p(z)p_\theta(x \mid z)dz$
encoder 近似后验

训练目标

ELBO：重构 $-$ KL
是 $\log p_\theta(x)$ 的下界

采样方式

$z \sim p(z)$，一次 decoder
再从 $p_\theta(x \mid z)$ 抽样

代价与失效

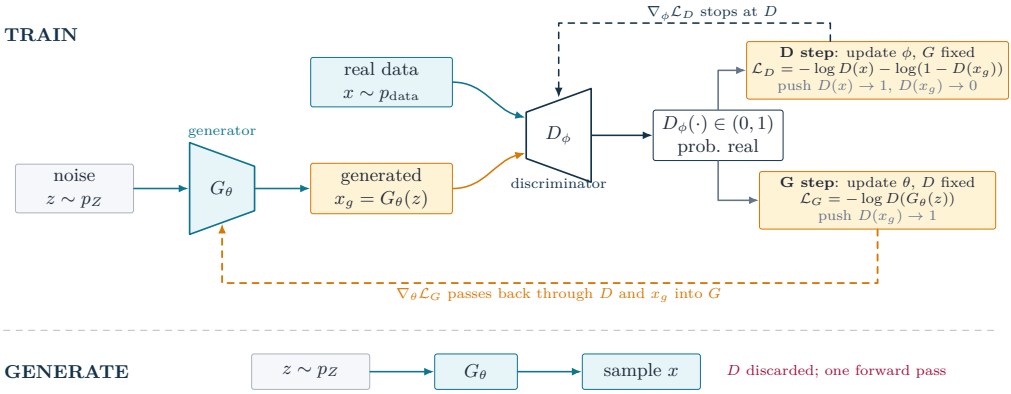
下界有间隙；样本偏模糊；posterior collapse

要点

VAE 用一个可优化的下界换掉难算的积分，并得到有意义的低维表示。今天的图像扩散模型常在 VAE 学出的潜空间里运行。

GAN：放弃似然

生成器与判别器



训练：两步交替。D step 固定 G，让真样本判 1、生成样本判 0；G step 固定 D，让 $D(G(z))$ 变大，梯度穿过 D 回到 G。

生成：丢掉 D，z 经 G 一次前向就是样本。D 只在训练中提供信号，整个模型不给出密度。

让一个分类器来当裁判

生成器 G_θ：$z \sim \mathcal{N}(0, I)$ 一次前向得到 $x = G_\theta(z)$，不给密度。判别器 D_ϕ 判断样本来自数据还是生成器：

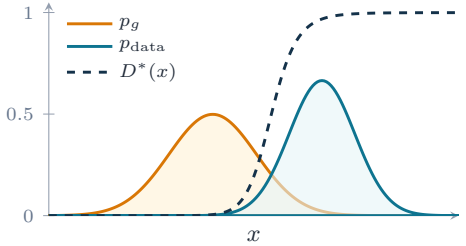
$$\min_\theta \max_\phi \; \mathbb{E}_{p_{\text{data}}} \log D + \mathbb{E}_z \log(1 - D(G(z)))$$

★ 关键一步

固定 G，最优判别器是密度比：

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$$

代回后生成器在最小化 $2\,\mathrm{JSD}(p_{\text{data}} \| p_g) - \log 4$。

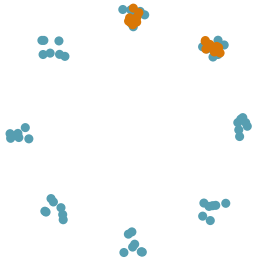


两样本检验与似然比　判别器是一个学出来的检验统计量：它分不清两组样本，两个分布才相同。

GAN 的代价

- 本讲唯一不以似然为目标的路线：没有密度，也报告不了样本的似然
- 训练是两个网络的博弈，交替更新不保证收敛；判别器过强时生成器梯度消失
- Mode collapse：生成器只覆盖少数容易骗过判别器的模式，行为接近第一讲的反向 KL
- 部署时一次前向，速度最快

另一种只用样本的办法：固定核函数，最小化两组样本的最大均值差异（MMD），不需要判别器。



数据：8 个模式

生成器：只覆盖 2 个

小结

GAN 用一个可学习的检验统计量代替似然：采样最快、样本锐利，代价是无密度、训练不稳定、容易丢模式。

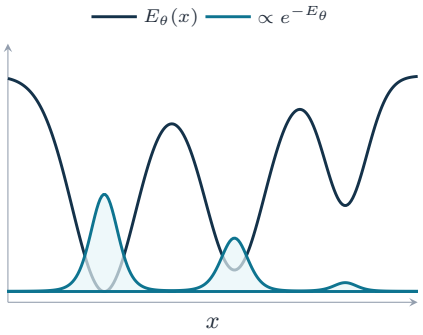
能量模型与 MCMC

用神经网络参数化玻尔兹曼分布

$$p_\theta(x) = \frac{e^{-E_\theta(x)}}{Z_\theta}, \qquad Z_\theta = \int e^{-E_\theta(x)} dx$$

- E_θ 可以是任意标量网络：表达最自由，不需要可逆，也不需要逐步分解
- 物理先验可以直接写进能量
- 代价全部落在 Z_θ 上：它同时出现在密度、采样和训练梯度中

玻尔兹曼分布　第一讲的形式，只是能量由数据学出来，温度并入 E_θ。



似然梯度：正相位与负相位

★ 关键一步

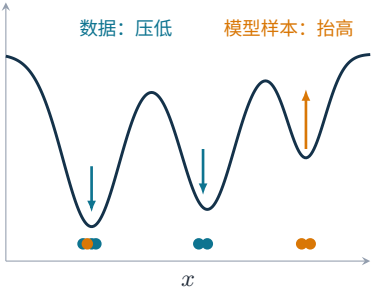
Z_θ 算不出来，它的对数梯度却是一个期望：

$$\nabla_\theta \log Z_\theta = \frac{1}{Z_\theta}\int -\nabla_\theta E_\theta \, e^{-E_\theta} dx = -\mathbb{E}_{p_\theta}[\nabla_\theta E_\theta]$$

于是负对数似然的梯度为

$$\nabla_\theta \mathcal{L} = \underbrace{\mathbb{E}_{p_{\text{data}}}[\nabla_\theta E_\theta]}_{\text{正相位}} - \underbrace{\mathbb{E}_{p_\theta}[\nabla_\theta E_\theta]}_{\text{负相位}}$$

- 正相位：压低数据处的能量
- 负相位：抬高模型样本处的能量，防止模型把所有能量都压低



两项平衡时，模型样本与数据分布一致。每一步更新前都要先从当前模型采样。

马尔可夫链蒙特卡洛

构造一条马尔可夫链 $x_0 \to x_1 \to \cdots$，使目标 π 是它的平稳分布；跑得足够久，状态就近似服从 π。

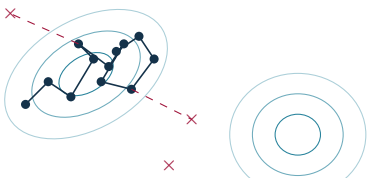
★ 细致平衡

若转移核满足 $\pi(x)K(x' \mid x) = \pi(x')K(x \mid x')$，对 x 求和即得 $\sum_x \pi(x)K(x' \mid x) = \pi(x')$，$\pi$ 是平稳分布。

Metropolis–Hastings：从 $q(x' \mid x)$ 提议，以

$$a = \min\Big\{1,\ \frac{\tilde{\pi}(x')\,q(x \mid x')}{\tilde{\pi}(x)\,q(x' \mid x)}\Big\}$$

接受，否则留在原地。只用到比值，Z 被约掉。



链在一个模式内游走；× 是被拒绝的提议。另一模式很难到达

马尔可夫链与平稳分布　遍历性保证极限存在；收敛快慢由混合时间决定。

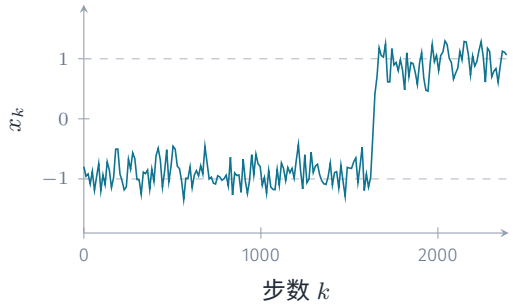
Langevin 动力学：沿梯度下坡，再加热噪声

连续变量时，用能量梯度构造提议：

$$x_{k+1} = x_k - \frac{\eta}{2}\nabla_x E(x_k) + \sqrt{\eta}\,\xi_k$$

- 下坡项推向低能区，噪声 $\xi_k \sim \mathcal{N}(0, I)$ 让样本有机会翻越势垒
- 连续极限以 e^{-E} 为平稳分布；有限步长的偏差可用 MH 校正
- 混合慢：势垒高时，链要很久才跨到另一个谷

布朗运动 $dx = -\frac{1}{2}\nabla E\,dt + dW_t$；第三讲的扩散模型用同一类随机微分方程。



双势阱 $E = (x^2-1)^2/T$ 中的一条 Langevin 链：长时间停在一个谷里，偶尔跃迁

训练能量模型的实际做法

每次参数更新都要负相位样本，而充分混合的链太贵。常用有偏但便宜的近似：

- **CD-k**：从数据点出发只跑 k 步，用短链终点作负样本；只修正数据附近的错误
- **持续链**：保存上一轮的链状态，下一轮接着跑；不必每次重新预热，但参数在变，链在追一个移动的目标

推理时同样要跑链：生成一个样本需要成百上千步。

概率对象	$p_\theta \propto e^{-E_\theta}$ 最灵活，未归一化
训练目标	正相位 − 负相位 （极大似然的梯度）
采样方式	MCMC / Langevin 多步迭代
代价与失效	负相位昂贵；混合慢；样本有偏

Score：一个与 Z 无关的量

$$s(x) = \nabla_x \log p(x) = -\nabla_x E(x)$$

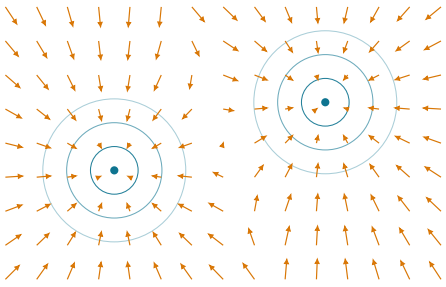
Z 对 x 是常数，求梯度后消失。score 是指向密度上升最快方向的向量场。

★ score matching

用 Fisher 散度比较两个分布：$D_F(p\|q) = \frac{1}{2}\mathbb{E}_p\|\nabla \log p - \nabla \log q\|^2$，它只看两者的 score 是否处处一致。取 $q = p_\theta$，分部积分去掉未知的 $\nabla \log p_{\text{data}}$：

$$D_F(p_{\text{data}}\|p_\theta) = \mathbb{E}_{p_{\text{data}}}\left[\frac{1}{2}\|s_\theta\|^2 + \nabla \cdot s_\theta\right] + C$$

只用数据样本，不需要负样本。



双峰分布的 score 场：箭头指向附近的模式

第二讲小结

	概率对象	训练目标	采样	主要代价
自回归	$\prod_t p(x_t \mid x_{<t})$	极大似然（交叉熵）	逐个抽样	串行
Flow	可逆变换 + Jacobian	精确极大似然	逆变换一次	结构受限
VAE	潜变量的连续混合	ELBO（下界）	decoder 一次	下界间隙、模糊
GAN	隐式分布	对抗博弈（JSD）	生成器一次	无密度、丢模式
能量模型	e^{-E_θ}/Z_θ	正相位 − 负相位	MCMC 多步	混合慢

要点

每一类模型都在“能否算出 $p(x)$”与“采样是否便宜”之间取舍。能量模型最灵活，却被采样拖累；score 绕开了 Z，但学到 score 之后怎样高效采样？如果在不同噪声水平上都学一个 score，会发生什么？这就是第三讲的扩散模型。