生成模型与概率统计

第三讲　从去噪到大模型

张士欣

中国科学院物理研究所　2026.10

github.com/refraction-ray/free-energy-to-llms



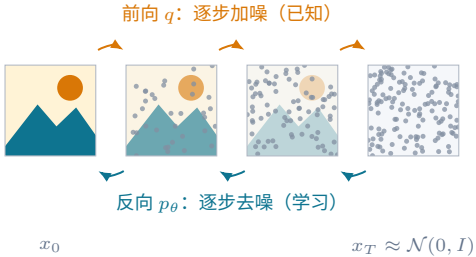
本讲路线

上一讲留下的线索

- 能量模型表达最自由，却被 MCMC 采样拖累
- score $\nabla_x \log p$ 与 Z 无关，可以只用数据学
- 难点：数据附近之外 score 学不准，链也混合不动

本讲三部分

1. 扩散模型：在许多噪声水平上学 score，把一次难采样拆成许多小步
2. Transformer：大语言模型用来表示 $p(x_t \mid x_{<t})$ 的网络
3. 大模型的训练阶段：从极大似然到带 KL 约束的奖励优化



扩散、score 与 Flow Matching

动机：一步太难，就拆成许多小步

- GAN、VAE 想一步把噪声变成数据：映射极其复杂，或只能优化下界
- 能量模型用 Langevin 一步步走，但在多峰分布里混合极慢
- 扩散的思路：人为规定一个从数据走向噪声的过程，它每一步都很简单、完全已知；只学习它的反向
- 每一小步的反向转移近似是高斯，只需学一个“往哪里走”的方向

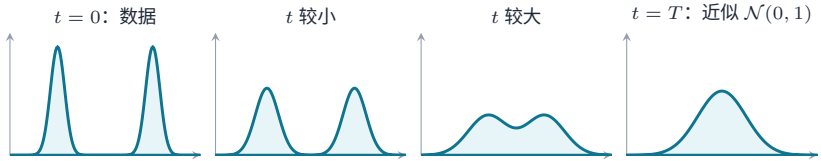
贝叶斯公式　已知前向 $q(x_t \mid x_{t-1})$，反向 $q(x_{t-1} \mid x_t) \propto q(x_t \mid x_{t-1})\, q(x_{t-1})$；难算的部分只剩带噪数据的分布。

关键想法

高噪声时分布接近高斯，简单；低噪声时细节丰富，但相邻两步很接近。生成就是从简单走向复杂，每一步只修正一点。

2015	非平衡热力学视角的扩散概率模型
2019	多噪声水平的 score 模型
2020	DDPM：噪声回归，图像质量追上 GAN
2021	随机微分方程统一框架
2022–	潜空间扩散、DiT、Flow Matching

前向加噪：任意时刻都有闭式解



DDPM 每一步 $q(x_t \mid x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}\, x_{t-1}, \beta_t I)$，合并后

$$x_t = \underbrace{\sqrt{\bar{\alpha}_t}}_{a_t}\, x_0 + \underbrace{\sqrt{1-\bar{\alpha}_t}}_{b_t}\, \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

其中 $\bar{\alpha}_t = \prod_{s \le t}(1-\beta_s)$。训练时直接抽 t, ϵ 合成 x_t，无需逐步模拟。

高斯卷积　独立高斯之和仍是高斯，方差递推 $v_t = \alpha_t v_{t-1} + \beta_t$ 解得 $1 - \bar{\alpha}_t$。带噪分布 p_t 是数据分布与高斯核的卷积：峰被抹平、最终只剩一个高斯。

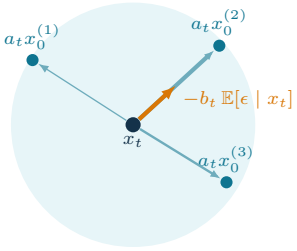
训练：让网络猜加进去的噪声

训练：噪声回归

1. 取数据 x_0，随机抽 t 与 $\epsilon \sim \mathcal{N}(0, I)$
2. 合成 $x_t = a_t x_0 + b_t \epsilon$
3. 最小化 $\|\epsilon - \epsilon_\theta(x_t, t)\|^2$

网络输入 x_t 与 t，所有 t 共用一个网络（U-Net 或 Transformer）。猜出噪声即猜出原图：$\hat{x}_0 = (x_t - b_t \epsilon_\theta)/a_t$。

条件期望　均方回归的最优解是条件期望：$\epsilon^*_\theta(x, t) = \mathbb{E}[\epsilon \mid x_t = x]$。同一个 x_t 有多种可能的来历，网络学到的是它们的后验平均，而不是某一份具体的噪声。



同一个 x_t 可能来自不同原图。青色：若原图是 $x_0^{(k)}$，去噪方向是 $-b_t \epsilon^{(k)}$，粗细表示后验 $p(x_0^{(k)} \mid x_t)$；橙色：网络学到的后验平均

为什么预测噪声就是在学 score

★ 关键一步

带噪分布是高斯混合，$q(x \mid x_0) = \mathcal{N}(a_t x_0, b_t^2 I)$：

$$p_t(x) = \int p_{\text{data}}(x_0)\, q(x \mid x_0)\, dx_0$$

对 x 求梯度，并利用 $\nabla q = q \nabla \log q$：

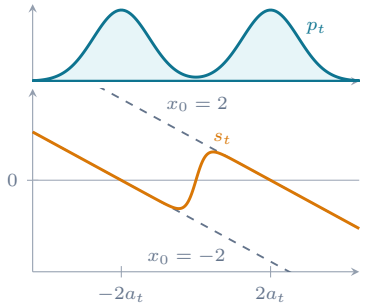
$$\nabla \log p_t(x) = \int \underbrace{\frac{p_{\text{data}}(x_0)\, q(x \mid x_0)}{p_t(x)}}_{\text{后验} p(x_0 \mid x_t = x)} \nabla \log q \, dx_0$$

$$= \mathbb{E}\left[-\frac{x - a_t x_0}{b_t^2} \;\middle|\; x_t = x \right]$$

$$= -\frac{1}{b_t} \mathbb{E}[\epsilon \mid x_t = x]$$

即各张原图的 score 按后验加权平均（用了 $x - a_t x_0 = b_t \epsilon$）。对照上一页：

$$s_t(x) \approx -\epsilon_\theta(x, t)/b_t$$



数据只有 $x_0 = \pm 2$ 两点（$a_t = 0.8$，$b_t = 0.6$）。虚线：两张原图各自的条件 score，都是直线；橙色：总 score。左边几乎全听 $x_0 = -2$，右边全听 $x_0 = 2$，中间按后验权重迅速切换

采样：从噪声一步步走回数据

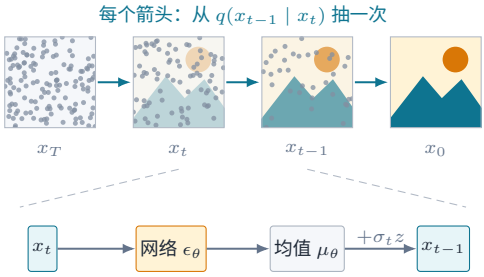
前向是一条已知的马尔可夫链 $x_0 \to x_1 \to \cdots \to x_T$。采样就是倒着走：每一步从反向转移 $q(x_{t-1} \mid x_t)$ 抽一个样本。

采样：逐步去噪

1. $x_T \sim \mathcal{N}(0, I)$
2. 对 $t = T, \ldots, 1$：抽 $z \sim \mathcal{N}(0, I)$（$t = 1$ 时取 $z = 0$），

$$x_{t-1} = \underbrace{\frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{b_t}\epsilon_\theta(x_t, t)\right)}_{\text{均值}\mu_\theta(x_t)} + \sigma_t z$$

3. 输出 x_0。共调用网络 T 次（DDPM 中 $T = 1000$）



上：生成方向，噪声逐步变成图像。下：放大其中一步

高斯近似　步长 β_t 很小时，反向一步近似高斯，只需知道均值和方差。方差 σ_t^2 由噪声调度定好；均值由网络算出，公式从哪来见下一页。

反向一步的均值从哪来

★ 关键一步

假如知道原图 x_0：由贝叶斯公式

$$q(x_{t-1} \mid x_t, x_0) \propto \underbrace{q(x_t \mid x_{t-1})}_{\text{前向一步}} \underbrace{q(x_{t-1} \mid x_0)}_{\text{闭式加噪}}$$

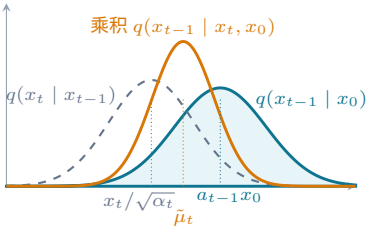
两个因子都是 x_{t-1} 的高斯，乘积仍是高斯，均值是两个中心按精度加权的平均：

$$\tilde{\mu}_t = \frac{\sqrt{\alpha_t}\, b_{t-1}^2}{b_t^2}\, x_t + \frac{a_{t-1}\beta_t}{b_t^2}\, x_0, \qquad \tilde{\beta}_t = \frac{b_{t-1}^2}{b_t^2}\, \beta_t$$

不知道 x_0：代入网络的估计 $\hat{x}_0 = (x_t - b_t\epsilon_\theta)/a_t$，化简得：

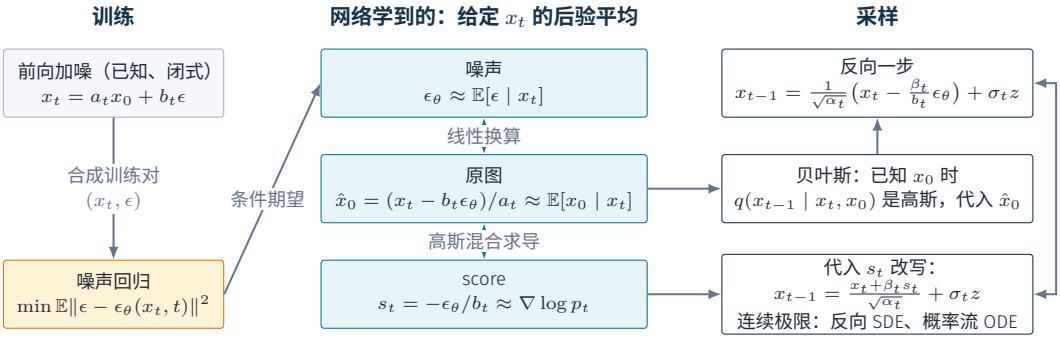
$$\mu_\theta(x_t) = \frac{1}{\sqrt{\alpha_t}}\Big(x_t - \frac{\beta_t}{b_t}\,\epsilon_\theta(x_t, t)\Big), \qquad \sigma_t^2 = \tilde{\beta}_t$$

这正是上一页算法里的均值。$\tilde{\mu}_t$ 对 x_0 线性，由全期望公式，代入 $\mathbb{E}[x_0 \mid x_t]$ 恰好得到 $\mathbb{E}[x_{t-1} \mid x_t]$。



横轴为 x_{t-1}。青色：从 x_0 往前加噪，x_{t-1} 应在哪里；灰色：要能一步走到 x_t，x_{t-1} 应在哪里。两者相乘：中心落在中间、偏向更窄的一方，宽度比两者都小

串起来：一个网络，三种读法

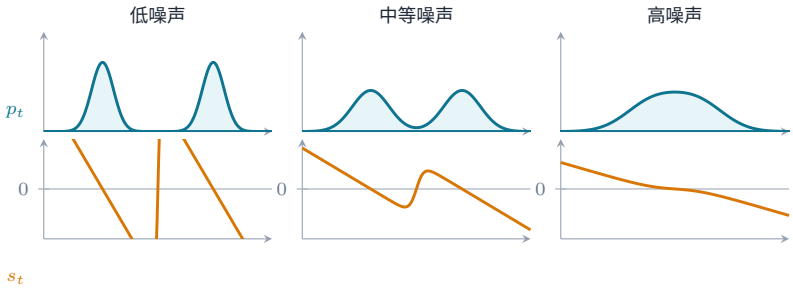


用到的概率工具：高斯卷积（前向）　条件期望（训练）　混合分布的梯度（score）　贝叶斯公式与全期望公式（采样）

要点

噪声、原图、score 只差线性换算，都是给定 x_t 的后验平均。训练只用条件期望；采样一步由贝叶斯公式推出，换成 score 写，连续极限就是后面的 SDE 与 ODE。

不同噪声水平的 score



要点

低噪声时 score 精细而陡峭，只在数据附近可靠；高噪声时 score 平滑，几乎是指向原点的线性场。采样从高噪声出发，先定大致位置，再逐级补细节，这避开了单一 score 在数据远处学不准、混合慢的问题。

连续时间：随机微分方程与概率流

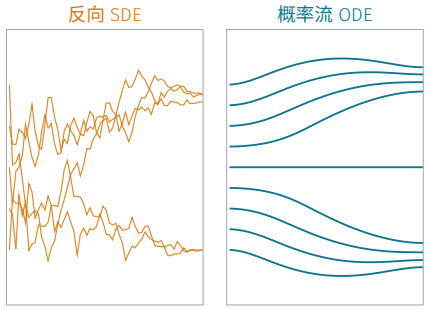
正向加噪写成 SDE：

$dx = f(x,t)\,dt + g(t)\,dW_t$。

- 反向 SDE（随机）：
  $dx = \big[f - g^2\, s_t(x)\big]dt + g\, d\bar{W}_t$
- 概率流 ODE（确定）：$\dfrac{dx}{dt} = f - \frac{1}{2}g^2\, s_t(x)$

两者在每个时刻的边缘分布 p_t 都相同，单条轨迹不同。缺的只有 score，正好由噪声网络给出。

Fokker–Planck 方程　密度演化中的扩散项可以改写成输运：$\partial_t p = -\nabla\cdot\big[(f - \frac{1}{2}g^2 s)\,p\big]$，这就是概率流 ODE 的来历。



横轴为生成时间。两种轨迹都落到两个模式上，ODE 轨迹互不相交

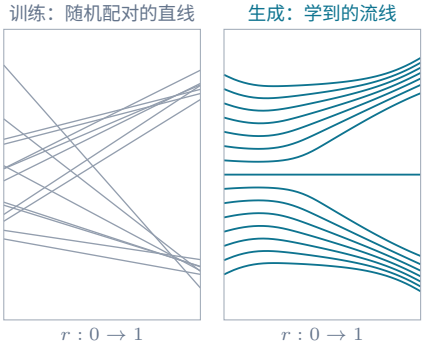
Flow Matching：直接学速度

取噪声 z 与数据 y，走直线 $x_r = (1-r)z + ry$，它的速度是 $y - z$：

$$\mathcal{L} = \mathbb{E}_{y,z,r}\left\| v_\theta(x_r, r) - (y - z) \right\|^2$$

- 同一个 x_r 可能来自许多对 (z, y)；最优解是条件平均 $v_r(x) = \mathbb{E}[y - z \mid x_r = x]$
- 训练只需随机取一个时刻做回归，不解任何 ODE
- 生成：$z \sim \mathcal{N}(0, I)$，沿 $dx/dr = v_\theta$ 积分到 $r = 1$

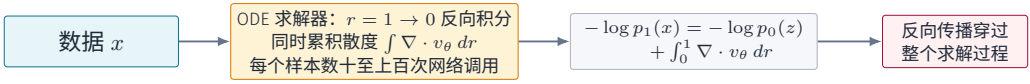
条件期望　和噪声回归同一个原理：对单对样本的回归，学到总体的速度场。



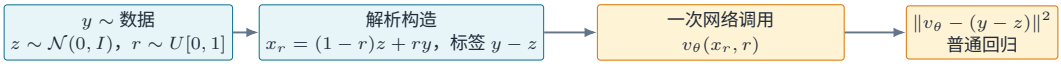
训练直线相互交叉；条件平均后的流线互不相交，并且弯曲

Flow Matching 与连续归一化流：同一个模型，两种训练

CNF：极大似然训练



Flow Matching：回归训练



推理（两者完全相同）：$z \sim \mathcal{N}(0, I)$，数值积分 $dx/dr = v_\theta(x, r)$ 得到样本；需要密度时同样沿轨迹积分散度

要点

训练从“每个样本解一次 ODE、积分散度、对整条轨迹反传”变成“随机取一个时刻、做一次回归”；学到的速度场和生成 ODE 与 CNF 完全相同。要学一个把高斯搬运成数据的速度场，训练时却不必模拟这个搬运；连续时间流因此能扩展到图像、视频等高维数据。

为什么回归条件速度就够了

★ 三步

条件路径：固定数据点 y，路径 $x_r = (1-r)z + ry$ 的速度 $u_r(x \mid y) = \frac{y-x}{1-r}$ 已知，条件密度 $p_r(x \mid y)$ 满足连续性方程。

叠加：令 $v_r(x) = \mathbb{E}[y - z \mid x_r = x]$，则

$$p_r(x)\, v_r(x) = \int p_{\text{data}}(y)\, p_r(x \mid y)\, u_r(x \mid y)\, dy$$

对 y 积分条件连续性方程，得 $\partial_r p_r + \nabla \cdot (p_r v_r) = 0$：$v_r$ 把 $\mathcal{N}(0, I)$ 恰好搬运成 p_{data}。

损失分解：

$$\mathbb{E}\big\|v_\theta - (y - z)\big\|^2 = \mathbb{E}\big\|v_\theta - v_r(x_r)\big\|^2 + C$$

同一个技巧在本讲出现了两次：把不可算的边缘目标换成可算的条件目标。

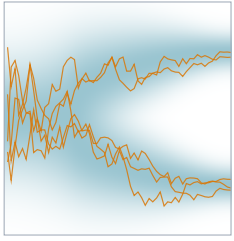
- **扩散**：边缘 score $\nabla \log p_t(x)$ $\rightarrow$ 条件 score $-\epsilon / b_t$
- **流**：边缘速度 $v_r(x)$ $\rightarrow$ 条件速度 $y - z$

条件期望　均方误差下，对条件目标回归与对边缘目标回归只差一个与参数无关的常数，最优解相同。

全景：一条概率之河

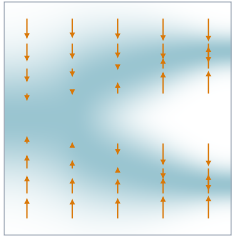
这几种方法做的是同一件事：选一条从高斯连续变到数据的概率路径 p_t，学一个向量场，让样本顺着它走回数据。下图横轴是生成时间（左为噪声，右为数据），纵轴是 x，颜色是 $p_t(x)$。

1 加噪：河由数据吹散而成



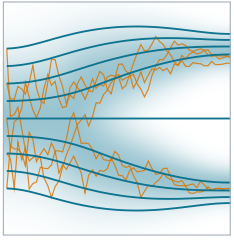
从数据向噪声扩散，已知

2 score：河面的坡度



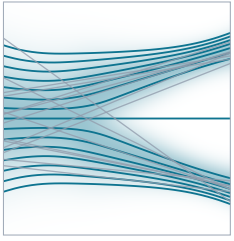
箭头 $\nabla \log p_t$ 指向密度高处

3 扩散采样：逆流走回



橙：反向 SDE；
青：概率流 ODE

4 Flow Matching：换一条直河



灰：训练直线；青：学到的流线

	河（概率路径）	网络学什么	怎么走回数据
扩散	逐步加噪 $x_t = a_t x_0 + b_t \epsilon$	score，即河面的坡度	反向 SDE 或概率流 ODE
Flow Matching	直线插值 $x_r = (1-r)z + ry$	速度，即水流本身	沿速度场积分 ODE

扩散：小结

概率对象

各噪声水平的 score $\nabla_x \log p_t$
（或噪声、速度）

训练目标

噪声 / score / 速度的均方回归
负 ELBO 的重加权

采样方式

从高斯出发，反向 SDE 或 ODE
数十到上千次网络调用

代价与失效

采样步数多；似然需另行积分

要点

扩散绕开了 Z（只学梯度），绕开了混合慢（噪声把各模式连通），也避开了对抗博弈（训练只是回归）。代价是采样要多步。文本也可以做“掩码扩散”：前向把 token 逐步换成 [MASK]，反向逐步填回，这与下面 BERT 的完形填空相连。

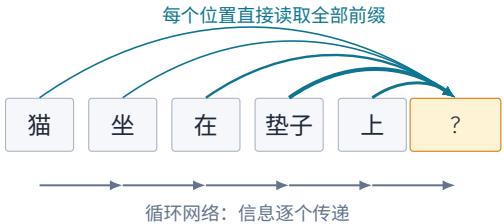
Transformer：怎样表示 $p(x_t \mid x_{<t})$

动机：需要一个读前缀、出分布的网络

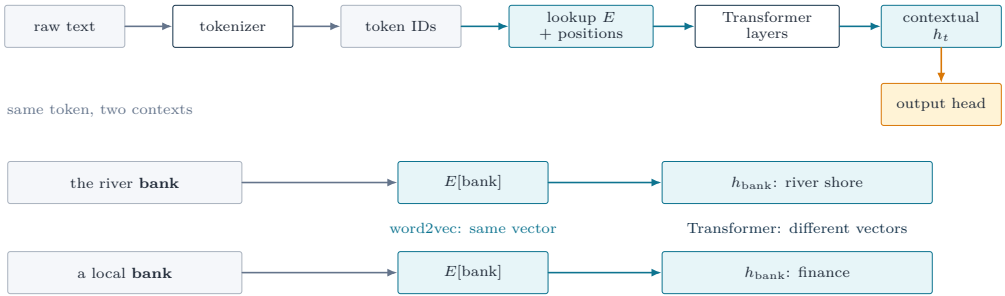
自回归模型要一个函数：输入任意长的前缀 $x_{<t}$，输出词表上的分布。

- **n-gram**：只看前 $n-1$ 个 token，查频率表；上下文短，表随 n 指数增长
- **循环网络**：把历史压进一个向量，逐个更新；训练也只能串行，长距离信息易丢失
- **Transformer**（2017）：每个位置直接按内容读取所有可见位置；训练时所有位置并行

马尔可夫假设　n-gram 是 $n-1$ 阶马尔可夫链；Transformer 不做截断，条件是整个前缀。

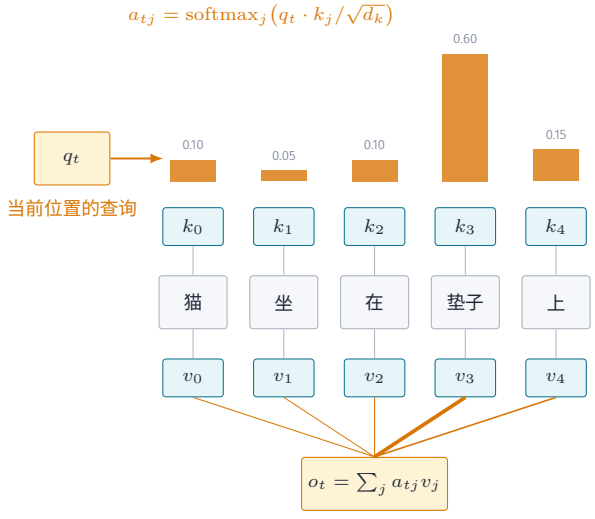


从文字到向量



- 分词器把文字切成 token 编号；编号只是类别标签，大小没有含义
- 嵌入矩阵 $E \in \mathbb{R}^{|\mathcal{V}| \times d}$ 为每个编号查一行向量；它与模型一起由训练损失更新
- 查表向量与上下文无关；经过 Transformer 层后，同一个 token 在不同句子中得到不同的表示

注意力：按内容加权平均

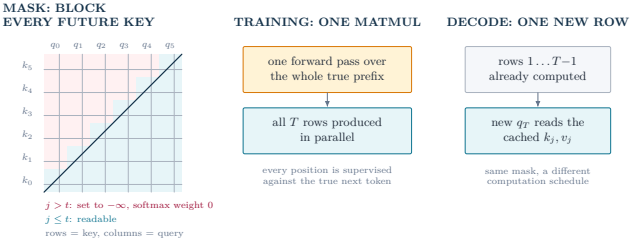


- query q：当前位置“想找什么”
- key k：每个位置“按什么被检索”
- value v：被读取的内容
- 三者都是同一表示经不同矩阵投影：$Q = XW_Q$，$K = XW_K$，$V = XW_V$

期望 权重 $a_{t\cdot}$ 是位置上的一个 categorical 分布；输出 o_t 是 value 在这个分布下的期望。softmax 又是玻尔兹曼分布：$-q \cdot k$ 扮演能量。

缩放点积注意力与因果 mask

$$\mathrm{Attn}(Q,K,V)=\mathrm{softmax}\Big(\frac{QK^\top}{\sqrt{d_k}}+M\Big)V,\qquad M_{tj}=0\ (j\le t),\quad M_{tj}=-\infty\ (j>t)$$



因果 mask 让位置 t 只看见 $x_{\le t}$：一次矩阵乘法给出所有位置的预测，标签不会泄漏。

独立和的方差　q,k 各分量独立、均值 0、方差 1 时 $\mathrm{Var}(q\cdot k)=d_k$；除以 $\sqrt{d_k}$ 让 logit 方差为 1，softmax 不会过早饱和。

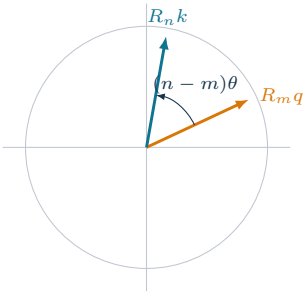
多头与位置

多头注意力

$$\mathrm{MHA}(X) = \mathrm{Concat}(\mathrm{head}_1, \ldots, \mathrm{head}_h)\, W_O$$

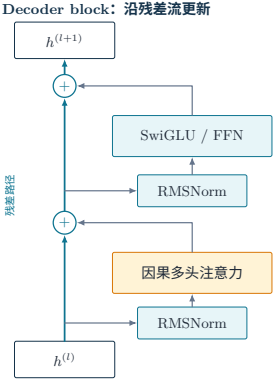
每个 head 有自己的 W_Q, W_K, W_V，在各自子空间里用不同的相似度检索：有的看语法搭配，有的看指代，有的看相邻位置。W_O 把各 head 的结果混合回残差流。

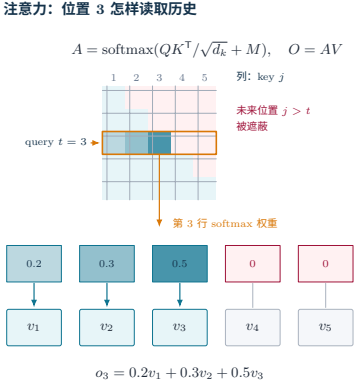
位置信息　注意力只看内容，打乱 token 顺序结果不变；必须另外注入位置。



RoPE：把 q, k 每两维看作平面向量，在位置 m 旋转角度 $m\theta$。内积 $(R_m q)^\top (R_n k) = q^\top R_{n-m} k$ 只依赖相对位置 $n - m$。

一个 Transformer block

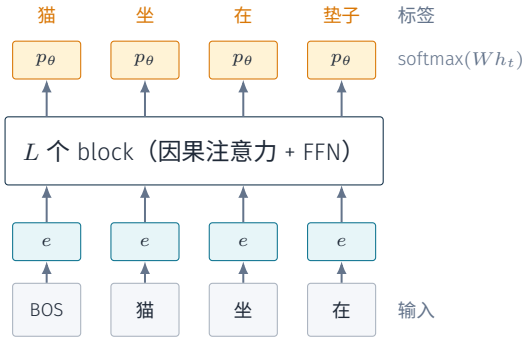




- **残差流**：$h \leftarrow h + \mathcal{F}(\mathrm{Norm}(h))$，每个子层只写入一个增量，深层也能稳定训练
- **注意力**在位置之间交换信息
- **FFN** 在每个位置内部做非线性特征变换
- **归一化**把每个 token 的向量调到稳定尺度

一个 block 堆叠 L 次（几十到上百层）。

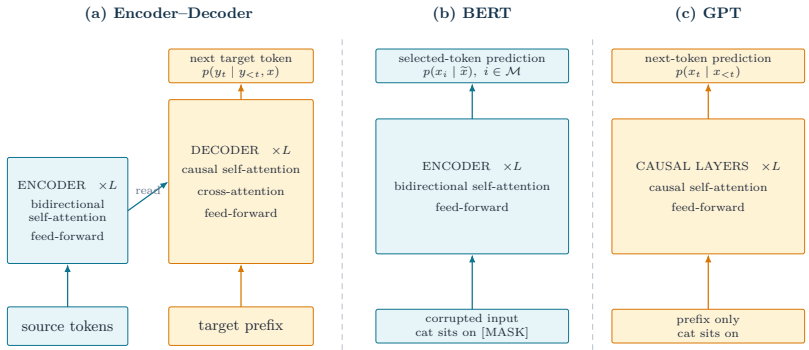
从最后一层到下一个 token 的分布



$$p_\theta(x_{t+1} = v \mid x_{\le t}) = \mathrm{softmax}\big(W h_t^{(L)}\big)_v$$

- **训练**：整段真实文本一次送入，每个位置都与下一个 token 计算交叉熵，即第二讲的极大似然
- **生成**：抽出一个 token 接到末尾，再算下一个位置；必须串行
- **KV cache**：前缀各位置的 k, v 不会再变，生成时缓存起来，每步只算新位置

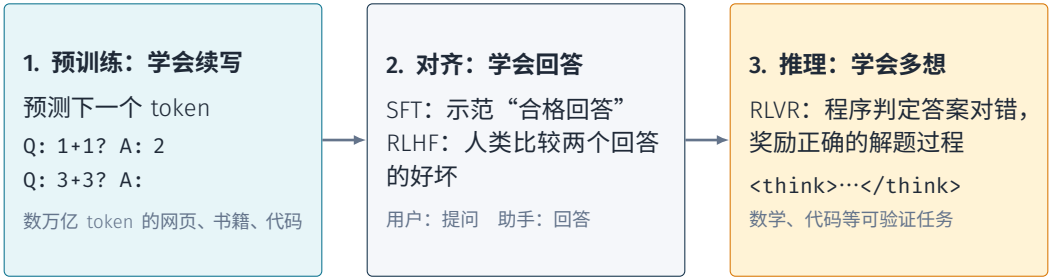
三种结构，三种条件分布



结构	学习的分布	用途
Encoder–Decoder	$p(y_t \mid y_{<t}, x)$	翻译等“读完再写”的任务
BERT	$p(x_i \mid \tilde{x})$：遮住一些词再猜回	文本表示、分类、检索
GPT	$p(x_t \mid x_{<t})$：预测下一个 token	续写、对话，今天的大语言模型

大模型的训练阶段

从续写到对话，再到推理



要点

三个阶段用的是同一个自回归模型 $\prod_t p_\theta(x_t \mid x_{<t})$，改变的是：经验分布由谁提供，以及目标里有没有奖励。

预训练与 SFT：同一个极大似然

预训练　在语料经验分布 $\hat{\pi}$ 上最小化 NLL，即 $\mathrm{KL}(\hat{\pi} \| p_\theta)$

- 数据配比 $\hat{\pi} = \sum_k \alpha_k \hat{\pi}_k$（网页、代码、数学、多语言……）本身就是在选择目标分布
- 参数量、数据量、算力需要按 scaling law 配平

SFT　换成“指令 c + 合格回答 y”的数据，损失只在回答 token 上计算：

$$\mathcal{L}_{\mathrm{SFT}} = -\mathbb{E}_{(c,y)} \sum_t \log p_\theta(y_t \mid y_{<t}, c)$$

经验分布与混合分布　预训练和 SFT 的差别只在 $\hat{\pi}$：前者覆盖所有文本，后者集中在“回答问题”这一小部分。

SFT 的局限　只有正例：模型学到“这样回答可以”，却学不到“另一种回答差多少”。比较好坏需要奖励或偏好。

RLHF：在参考分布附近提高奖励

给回答打分的奖励 $r(x)$ 来自人类偏好训练的奖励模型或程序判题器。目标：提高奖励，又不远离参考模型 p_0（通常是 SFT 模型）。

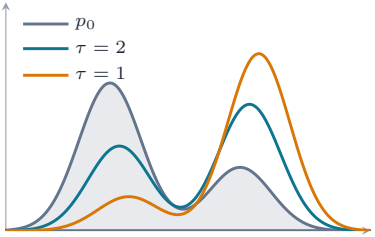
★ 关键一步

$$\mathbb{E}_q[r] - \tau \mathrm{KL}(q\|p_0) = -\tau\, \mathbb{E}_q\left[\log q - \log p_0 - \tfrac{r}{\tau}\right]$$

$$= -\tau\, \mathrm{KL}(q\|q^*) + \tau \log Z$$

所以最优策略是 $q^* = p_0\, e^{r/\tau}/Z$。

玻尔兹曼分布与自由能　奖励是负能量，τ 是温度，p_0 是先验测度；目标就是第一讲的变分自由能。



奖励 $r(x) = x$：τ 越小，概率越向高奖励一侧移动；但只能在 p_0 已有质量的地方重新分配

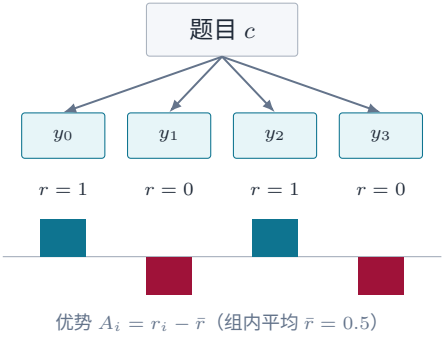
奖励怎样传回每个 token

回答 y 是逐 token 抽出的离散序列，梯度不能穿过抽样，用 score-function 估计：

$$\nabla_\theta \mathbb{E}_{y\sim\pi_\theta}[r] = \mathbb{E}\Big[(r-b)\sum_t \nabla_\theta \log \pi_\theta(y_t \mid y_{<t}, c)\Big]$$

PPO	另训一个价值网络作基线 b，每个位置的优势不同
GRPO	同一题采样一组回答，以组内平均分作基线
DPO	不在线采样，直接用“好 / 差”回答对拟合 q^*

score-function 估计　第二讲的另一条梯度路径；基线 b 不改变期望，只降低方差。



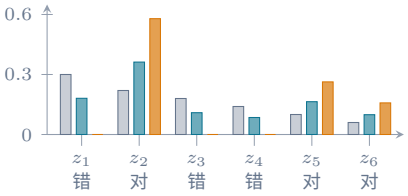
GRPO：答对的整条轨迹各 token 概率被抬高，答错的被压低。

推理模型：RLVR 与思维链

回答 $y=(z,a)$：先写推理链 z，再给答案 a。数学、代码可由程序判对错：$r(y)=\mathbf{1}[a \text{ 正确}]$。

- 目标 $\mathbb{E}_{\pi_\theta}[r]=\sum_z \pi_\theta(z\mid c)\,P(a \text{ 对}\mid z,c)$：推理链像隐变量一样被求和；奖励只看答案，不需要标注解题步骤
- 用上一页的 GRPO 训练：答对的整条推理链被抬高
- 训练中回答变长，自发出现验算、回退（OpenAI o1，2024；DeepSeek-R1，2025）。多写的 token 就是额外的串行计算

局限　判题器要可靠；只看答案时，过程可能是碰对的。p_0 几乎不写的推理方式很难被采到，也就很难得到奖励。



六条推理链：灰为 p_0，青为 $\tau=1$，橙为 $\tau\to 0$。p_0 下答对的概率是 0.38

条件概率　代入 RLHF 页的 $q^*=p_0e^{r/\tau}/Z$，r 只取 0 或 1：

$$q^*(y)\propto p_0(y)\,e^{r(y)/\tau}\xrightarrow{\tau\to 0}p_0(y\mid \text{答对})$$

答对的链按原有相对概率放大 $1/0.38$ 倍，答错的被剔除。

全课回顾：六条路线

算出 $p(x)$	**分解　自回归** $p(x)=\prod_t p(x_t \mid x_{<t})$ 精确似然；逐个采样，串行 链式法则	**变换　Flow** $x=f_\theta^{-1}(z),\ z\sim\mathcal{N}(0,I)$ 精确似然；可逆结构受限 随机变量的变量替换	**隐变量　VAE** $p(x)=\int p(z)\,p_\theta(x \mid z)\,dz$ 只能优化下界 边缘化、Jensen 不等式
绕开归一化	**对抗　GAN** $x=G_\theta(z)$ 不给密度，只比较样本 两样本检验	**能量　EBM** $p(x)\propto e^{-E_\theta(x)}$ 未归一化；靠马尔可夫链采样 玻尔兹曼分布、MCMC	**去噪　扩散** $s_\theta(x,t)\approx\nabla_x \log p_t(x)$ 学习各噪声水平的 score 高斯卷积、条件期望、SDE

Transformer 是第一张卡片里的条件分布网络；扩散模型的去噪网络也常用它。大模型的后训练回到第一讲的自由能。

全课小结

带走的几件事

1. 生成模型的核心问题只有一个：用样本学一个高维分布，并能从中抽样；难点集中在归一化常数 Z
2. 训练目标都是分布之间的差距：极大似然是前向 KL，变分推断与 RLHF 是反向 KL（自由能），GAN 是 JSD，score matching 是 Fisher 散度
3. 各类模型的区别在怎样处理 Z：分解、变换、下界、放弃密度、只用比值、只用梯度
4. 扩散把一次困难的采样拆成许多次简单的去噪；关键一步是“噪声回归学到的后验平均恰好就是 score”
5. 大语言模型 $=$ 链式法则 $+$ Transformer $+$ 极大似然，再用带 KL 约束的奖励优化做对齐

附录

附录：反向扩散与 Langevin，像在哪，不同在哪

★ 换成 score 的写法

代入 $\epsilon_\theta = -b_t s_t$，采样的一步是

$$x_{t-1} = \frac{x_t + \beta_t\, s_t(x_t)}{\sqrt{\alpha_t}} + \sigma_t z$$

第二讲的 Langevin 是

$$x \leftarrow x + \tfrac{\eta}{2}\, s(x) + \sqrt{\eta}\, z$$

形式相同：沿 score 走一步，再加高斯噪声。

拆开看　步长小时 $\sigma_t^2 \approx \beta_t$。忽略 $\sqrt{\alpha_t}$ 的缩放，一步的增量拆成两半：

$$\beta_t s_t + \sqrt{\beta_t}\, z = \underbrace{\tfrac{1}{2}\beta_t s_t + \sqrt{\beta_t}\, z}_{\eta=\beta_t \text{ 的 Langevin}} + \underbrace{\tfrac{1}{2}\beta_t s_t}_{\text{确定性输运}}$$

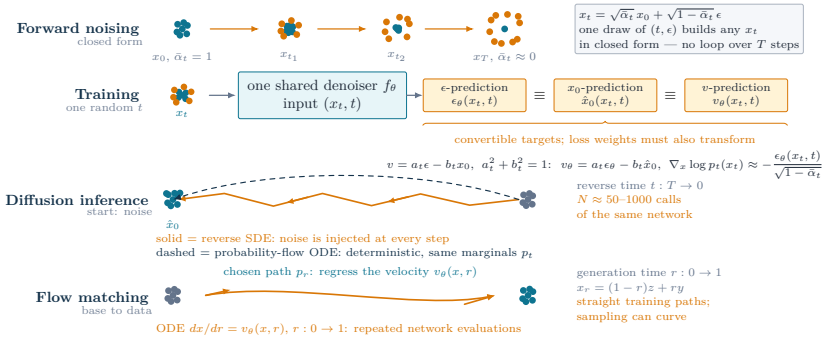
前一半只在 p_t 内部搅动，不改变分布；后一半把 p_t 推向 p_{t-1}，就是正文的概率流 ODE。

	Langevin	反向扩散
目标	一个固定的 p	一串分布 $p_T \to p_0$
score	每步相同	每步换成 s_t
每一步	保持 p 不变	把 p_t 变成 p_{t-1}
步数	等链混合，事先不知	正好 T 步
多峰	卡在一个峰里	高噪声时峰已连通

要点

Langevin 在一个固定分布里反复游走，要等它混合；反向扩散每一步都换一个分布，顺着 $p_T \to \cdots \to p_0$ 走下来，走完 T 步就是数据的样本。

附录：一个统一的图景



要点

DDPM 学噪声（等价于 score），用随机的反向转移生成；同一个网络也可以沿概率流 ODE 确定性地大步采样（下一页：DDIM）；Flow Matching 直接学选定路径上的速度。在高斯路径上，噪声、干净样本、score 与速度可以互相换算，差别在路径、损失权重和求解器。

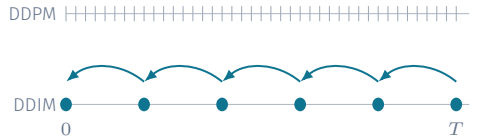
附录：DDIM，同一个网络，更少的步数

在当前 x_t 调用一次网络，先估计干净样本，再按更早时刻 $s < t$ 的系数重新组合：

$$\hat{x}_0 = \frac{x_t - b_t\,\epsilon_\theta(x_t, t)}{a_t},$$

$$x_s = a_s \hat{x}_0 + b_s\,\epsilon_\theta(x_t, t)$$

- 训练不变，只改采样器；不再注入新噪声，相当于沿概率流 ODE 走大步
- 1000 步训练调度，生成时只取 50 个时刻
- 更好的 ODE 求解器、蒸馏等方法还能进一步压到几步



要点

扩散的计算成本主要来自步数；训练出的 score 网络可以配不同的采样器。

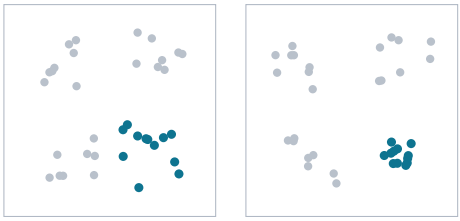
附录：条件生成，classifier-free guidance

训练时随机丢掉一部分样本的条件 c（如文本描述），同一个网络既能给出 $\epsilon_\theta(x_t, t, c)$，也能给出 $\epsilon_\theta(x_t, t, \varnothing)$。采样时

$$\epsilon_{\text{guide}} = \epsilon_{\text{uncond}} + w\,(\epsilon_{\text{cond}} - \epsilon_{\text{uncond}})$$

贝叶斯公式

$\nabla \log p(x \mid c) = \nabla \log p(x) + \nabla \log p(c \mid x)$。引导相当于从 $p(x)\,p(c \mid x)^w$ 采样：$w > 1$ 把似然放大，样本更贴合条件，多样性下降。



青色：条件 c 下的样本；灰色：其他类别

文生图模型中的“提示词相关度”参数就是 w；每步需要两次网络调用。