生成模型：从自由能到大模型

第一周　生成模型怎样处理 $p(x)$

张士欣

中国科学院物理研究所　2026.11

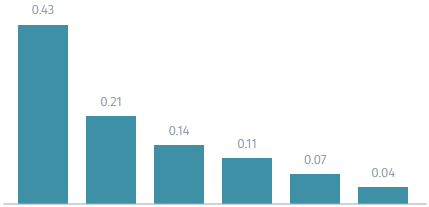
github.com/refraction-ray/free-energy-to-llms



生成式 AI 每天在做什么

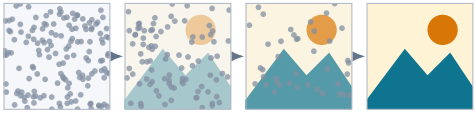
今天天气很 __

提示词 $x_{<t}$



下一个 token（词元）的条件分布 $p_\theta(x_t \mid x_{<t})$

抽一个 token，接到末尾，再算下一个分布



$t = T$ $t = 0$

纯噪声 ⟶ 逐步去噪 ⟶ 图像

每一步都从一个条件分布中抽样

要点

文本续写和图像生成看起来不同，做的是同一件事：先用数据学出一个高维概率分布，再从中抽样。这两周讨论这件事在数学上怎样实现。

本课的问题

给定来自未知分布的样本

$$x^{(1)}, \dots, x^{(N)} \sim p_{\text{data}},$$

找一个模型 $p_\theta \approx p_{\text{data}}$，并回答三个问题：

- **表示**：用什么函数族写出 p_θ？
- **学习**：用什么目标衡量 p_θ 与 p_{data} 的差距？
- **采样**：怎样从 p_θ 中抽出新的 x？

条件版本 $p_\theta(x \mid c)$ 中，c 可以是文字描述、目标性质或提示词。

对象	x 的形式
图像	$256 \times 256 \times 3 \approx 2 \times 10^5$ 维连续向量
文本	长度 T 的 token 序列，词表约 10^5
分子	原子种类与 $3N$ 个坐标
自旋	$\{\pm 1\}^N$ 上的构型

难点　维度极高；数据集中在复杂的低维结构附近；只能看到有限样本。

两周路线

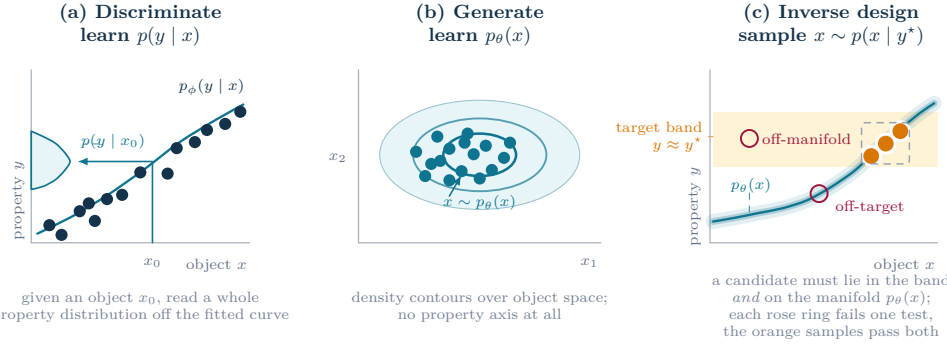
第一周	**生成模型怎样处理 $p(x)$**	判别、生成与逆向设计；怎样比较两个分布；自由能；自回归、Normalizing Flow（标准化流）、VAE（变分自编码器）、GAN（生成对抗网络）、能量模型与 MCMC
第二周	**从去噪到大模型**	扩散、score 与 Flow Matching；Transformer 与 KV cache；大模型的训练阶段；生成模型放回科学计算；数据与评价

每个模型都回答四个问题

概率对象	密度、条件概率、能量，还是密度的梯度？	训练目标	优化哪个散度或下界？
采样方式	一次前向、逐步生成、解微分方程，还是马尔可夫链？	代价	成本与失效模式在哪里？

判别、生成与逆向设计

同一批对象，三种问题



条件概率　判别模型学 $p(y \mid x)$：给定对象预测性质。生成模型学 $p(x)$：哪些对象本身合理。逆向设计要的是 $p(x \mid y)$：满足目标性质、又仍然合理的对象。

生成模型要提供的两种基本能力

采样 $x \sim p_\theta$

生成新图像、新分子
续写一段文本
为蒙特卡洛提供样本

评估密度 $p_\theta(x)$

判断一个样本是否合理
异常检测、模型比较
重要性重加权

条件化：把 c 作为输入，两种能力都有条件版本 $p_\theta(x \mid c)$。
逆向设计、文生图、按提示词回答都属于这一类。

要点

很少有模型能同时廉价地做好这两件事：GAN（生成对抗网络）采样快但给不出密度；能量模型的密度写法最灵活，采样却很慢；自回归模型两者兼有，代价是只能逐个生成。本周后半的各类模型就是在这里做不同的取舍。

想一想：直接优化预测器

训练好一个性质预测器 $f_\phi(x)$：输入材料结构 x，输出某项性能。它在测试集上误差很小。

逆向设计最直接的做法：从某个 x 出发做梯度上升

$$x \leftarrow x + \eta \nabla_x f_\phi(x),$$

一直走到预测性能刷新纪录。

问题

这样得到的 x，是一个好材料吗？

A 是：预测器在测试集上很准

B 不一定：那它会是什么？

逆向设计：先验乘以似然

$$p(x \mid y^\star) = \frac{p_\phi(y^\star \mid x)\, p_\theta(x)}{p(y^\star)}$$

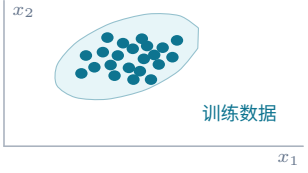
先验 $p_\theta(x)$ — 生成模型：这个 x 像不像真实数据？

似然 $p_\phi(y^\star \mid x)$ — 性质预测器：这个 x 达到目标 $y^\star$ 了吗？

分母 $p(y^\star)$ — 与 x 无关，只负责让总概率为 1

先验 $p_\theta(x)$

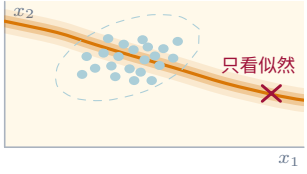
生成模型：哪些设计像真的



×

似然 $p_\phi(y^\star \mid x)$

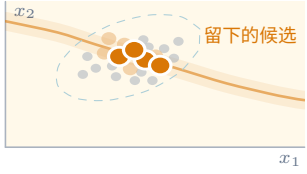
性质预测器：哪些设计达到目标



⇒

后验 $p(x \mid y^\star)$

两个条件同时满足



回到问题　多半不是。预测器 p_ϕ 只在训练数据附近可靠，只最大化似然，会一路走到数据之外、预测器误判的地方（中图 ×）。图像上有同样的现象：优化出来的条纹图案，被分类器以 99% 以上的置信度认作“海星”（Nguyen 等，2015）。乘上先验后，留下的候选既达到目标，又像真实数据。

条件分布从哪里来：两条路线

路线 A：先建模，再用贝叶斯公式拼出来

$$p(x \mid y) = \frac{p_\phi(y \mid x)\, p_\theta(x)}{p(y)}, \quad p(y) = \int p_\phi(y \mid x)\, p_\theta(x)\, dx$$

分子对任意 x 都能逐点算；分母 $p(y)$（记作 Z_y）要对所有 x 积分，高维时算不出来。绕开分母：

- **马尔可夫链蒙特卡洛（MCMC）**：只用两个候选的后验之比，分母约掉
- **变分推断**：用可算的 q 逼近后验，分母只贡献常数

路线 B：直接学习条件分布

$$\max_{\psi} \mathbb{E}_{(x,y)} \log p_\psi(x \mid y)$$

- y 作为网络输入：文生图里是文字描述，大语言模型里是提示词
- 网络结构保证归一化，没有分母要算

	路线 A：先验 × 似然	路线 B：直接学 $p_\psi(x \mid y)$
需要的数据	大量无标签的 x，加少量带性质的 (x, y)	大量配对的 (x, y)
换一个目标性质	只换预测器 p_ϕ，先验可复用	重新收集配对数据、重新训练
主要代价	归一化常数 Z_y：推断慢、只能近似	配对数据昂贵

归一化常数 Z 是贯穿全课的难点，后面每个模型都要说明它怎样处理 Z。

怎样比较两个分布

KL 散度与极大似然

手中有 p_{data} 的样本和一个模型 p_θ，需要衡量两者的差距。最常用的是 KL 散度（相对熵）：

$$\mathrm{KL}(p\|q) = \mathbb{E}_{x\sim p}\left[\log \frac{p(x)}{q(x)}\right] \geq 0$$

- 由 Jensen 不等式非负，等号当且仅当 $p = q$
- 不对称：$\mathrm{KL}(p\|q) \neq \mathrm{KL}(q\|p)$，期望取在哪个分布下，哪里的误差就被重视

其他散度在用到时再介绍：GAN 对应 Jensen–Shannon 散度，score matching 对应 Fisher 散度。

★ 关键一步

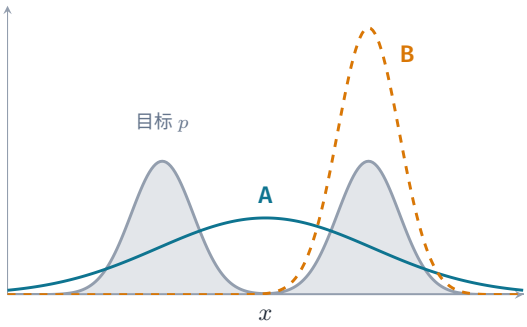
数据集 $\{x^{(i)}\}_{i=1}^N$ 给出经验分布 $\hat{\pi}$，每个样本权重 $1/N$：

$$\mathrm{KL}(\hat{\pi}\|p_\theta) = \underbrace{\mathbb{E}_{\hat{\pi}}[\log \hat{\pi}]}_{\text{与}\theta\text{ 无关}} - \frac{1}{N}\sum_{i=1}^{N} \log p_\theta(x^{(i)})$$

最小化前向 KL，就是极大似然。训练只需要数据样本，以及能逐点计算 $\log p_\theta(x)$。

极大似然估计（MLE） 在模型族里找离经验分布最近的分布。MSE 是高斯噪声下的极大似然，交叉熵是 categorical 分布下的极大似然。

想一想：一个高斯拟合两个峰



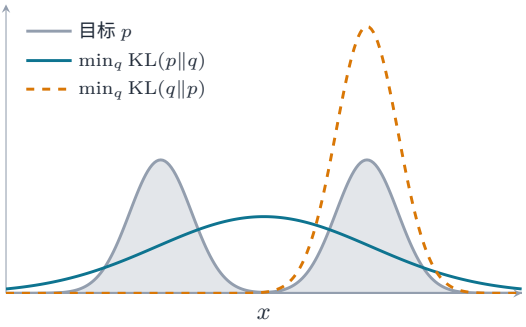
目标 p 有两个峰，模型 q 却只能是一个高斯。

问题

哪一个 q 离 p 更近？

A 横跨两峰的宽高斯
B 只盖住一个峰的窄高斯

两个方向，两种行为



用单个高斯 q 拟合双峰目标 p：

- 前向 KL 在 p 下取期望：p 有质量而 $q \approx 0$ 处代价极大，q 只好横跨两峰
- 反向 KL 在 q 下取期望：q 只需留在 p 的高概率区，于是落在一个峰上

回到问题 A、B 各是一个方向的最优解，“更近”取决于期望取在哪个分布下。A 覆盖所有模式，峰值却落在 p 几乎没有概率的地方；B 的样本都像真的，却丢掉一个模式。后面比较 VAE、GAN 时会再用到这张图。

反向 KL 就是变分自由能

目标是玻尔兹曼分布 $\pi(x) = e^{-\beta E(x)}/Z$。$Z$ 通常算不出来：$N = 100$ 个 Ising 自旋就有 $2^{100} \approx 10^{30}$ 个构型。用一个可采样、可算密度的分布 q 去逼近它：

★ 关键一步

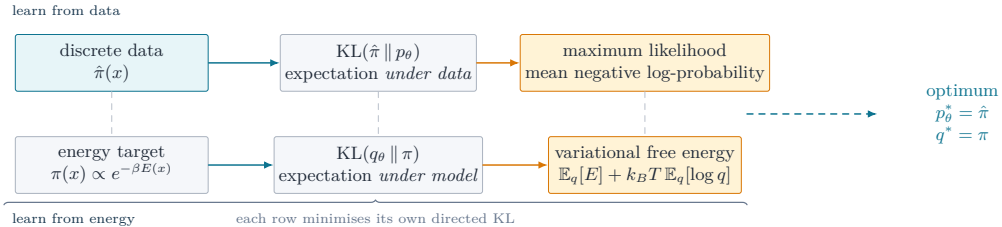
$$\mathrm{KL}(q\|\pi) = \mathbb{E}_q[\log q] + \beta\,\mathbb{E}_q[E] + \log Z = \beta\big(F[q] - F\big) \geq 0,$$

$$F[q] = \underbrace{\mathbb{E}_q[E]}_{\text{平均能量}} - T \underbrace{S[q]}_{-k_B\mathbb{E}_q[\log q]}, \qquad F = -k_B T \log Z$$

- 最小化反向 KL 等价于最小化变分自由能 $F[q]$，下界 F 在 $q = \pi$ 时取到
- 需要从 q 采样，并能逐点算出 $E(x)$ 与 $\log q(x)$（熵项要用）；不需要 Z，也不需要数据

变分原理　能量项把 q 推向低能构型，熵项阻止 q 塌缩到一点；平衡就是低能与高熵的折中。平均场近似就是取 q 为各自旋独立的乘积。

两种学习情形



手中有什么	目标	期望在谁下	典型问题
数据样本 $\hat{\pi}$	$\mathrm{KL}(\hat{\pi}\|p_\theta)$：极大似然	数据	生成模型训练（本周与下周）
能量函数 $E(x)$	$\mathrm{KL}(q\|\pi)$：变分自由能	模型	统计物理采样、变分推断、RLHF（基于人类反馈的强化学习，下周）

归一化常数：反复出现的难点

同一个积分以不同面目出现：

- 贝叶斯后验中的 Z_y
- 玻尔兹曼分布中的 Z
- 任何写成 $p_\theta = \tilde{p}_\theta / Z_\theta$ 的模型

高维积分难算，也让采样变难：不知道 Z，就没法像查分布表那样直接抽出独立样本，只能用 MCMC 这类只依赖概率比值的方法，代价是链要混合、样本彼此相关。

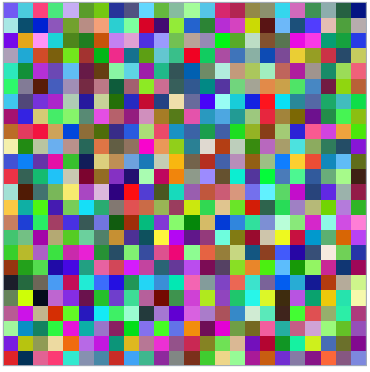
处理方式	对应模型
构造上自动归一化	自回归、Flow
优化一个下界	VAE
不需要密度	GAN
只用密度比值	能量模型 + MCMC
只用 $\nabla_x \log p$	score matching、扩散

要点

各类生成模型的一个主要区别，就是怎样对付 Z。

生成模型地图

想一想：随机涂像素



随机抽出的一张“图”

一张 256×256 的彩色图，每个像素的 R、G、B 各从 0–255 中随机取值。

问题

平均要抽多少次，才能抽到一张看起来像照片的图？

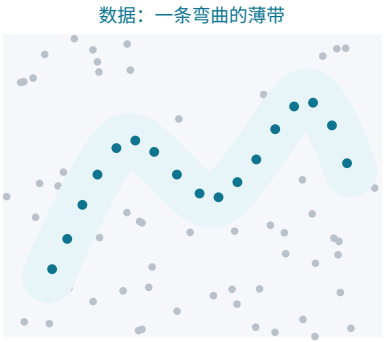
A 约 10^{10} 次
B 约 10^{100} 次
C 宇宙寿命内也抽不到

高维分布难在哪里

回到问题 C。可能的图共有 $256^{3\times256\times256} = 256^{196608} \approx 10^{473000}$ 张，而宇宙中的原子约 10^{80} 个。真实照片只占其中极薄的一层（右图浅蓝带），随机抽样几乎永远落在它外面。

- **维度灾难**：每维分 M 格，直方图需要 M^d 个格子。$M = 10$、$d = 100$ 时是 10^{100}
- **集中在低维结构**：真实图像只占像素空间中极小的一部分，随机像素几乎从不像一张照片
- **只有有限样本**：要从 N 个点推断整个分布，还要能生成没见过的样本

于是需要三样东西：灵活的函数族（神经网络）、只依赖样本的训练目标（如极大似然）、可执行的采样程序。



六条路线

算出 $p(x)$	**分解　自回归** $p(x) = \prod_t p(x_t \mid x_{<t})$ 精确似然；逐个采样，串行 链式法则	**变换　Flow** $x = f_\theta^{-1}(z),\ z \sim \mathcal{N}(0, I)$ 精确似然；可逆结构受限 随机变量的变量替换	**隐变量　VAE** $p(x) = \int p(z)\, p_\theta(x \mid z)\, dz$ 只能优化下界 边缘化、Jensen 不等式
绕开归一化	**对抗　GAN** $x = G_\theta(z)$ 不给密度，只比较样本 两样本检验	**能量　EBM** $p(x) \propto e^{-E_\theta(x)}$ 未归一化；靠马尔可夫链采样 玻尔兹曼分布、MCMC	**去噪　扩散** $s_\theta(x, t) \approx \nabla_x \log p_t(x)$ 学习各噪声水平的 score 高斯卷积、条件期望、SDE

上一行能算出（或界住）$p(x)$，下一行绕开归一化；底部是每条路线借用的概率工具。

自回归：把联合分布拆开

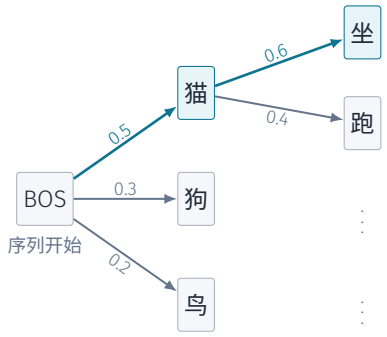
链式法则

对序列 $x = (x_1, \ldots, x_T)$，恒有

$$p(x) = \prod_{t=1}^{T} p(x_t \mid x_{<t})$$

- 直接给每个序列赋概率要 $|\mathcal{V}|^T$ 个数；$|\mathcal{V}| = 10^5$、$T = 1000$ 时是 10^{5000}
- 分解后每一步只需一个 $|\mathcal{V}|$ 类的 categorical 分布，由同一个网络读入前缀给出
- 每个因子都已归一化，乘积自动归一化：$Z = 1$

链式法则　恒等式，不含近似；近似只在用网络表示条件分布这一步。



$p(\text{猫}, \text{坐}) = 0.5 \times 0.6 = 0.3$

顺序同时规定了采样程序：沿树从根走到叶。图像也可以排成序列，从左到右、从上到下逐个生成：早期逐像素；现在多先压成离散 token 网格，一个 token 对应一小块区域。

从极大似然到逐 token 交叉熵

★ 关键一步

把链式分解代入前面的 MLE：

$$-\frac{1}{N}\sum_{i}\log p_\theta(x^{(i)}) = -\frac{1}{N}\sum_{i}\sum_{t}\log p_\theta\big(x_t^{(i)} \mid x_{<t}^{(i)}\big) = \frac{1}{N}\sum_{i}\sum_{t}\mathrm{CE}\big(e_{x_t^{(i)}},\, \pi_{\theta,t}\big)$$

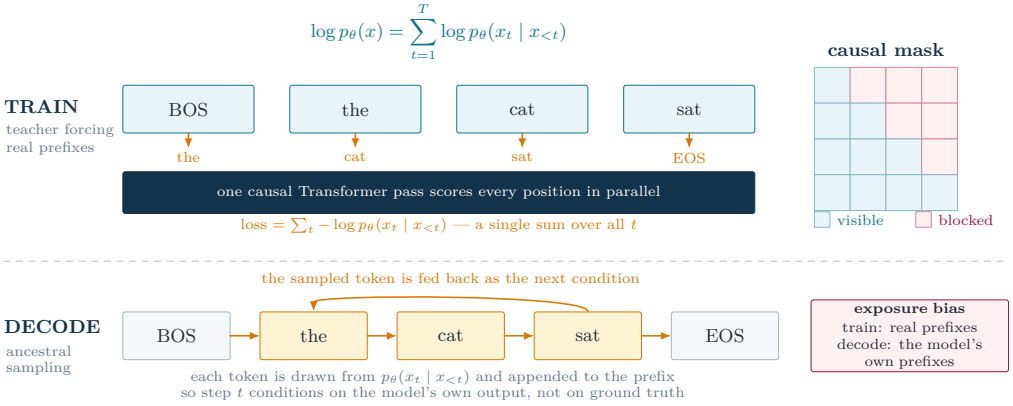
其中 $\pi_{\theta,t}$ 是网络在位置 t 输出的词表分布，e_{x_t} 是真实 token 的 one-hot 向量。

- 每个位置都是一道 $|\mathcal{V}|$ 类的分类题，标签是真实的下一个 token
- 一条序列提供 T 道题，全部无须人工标注

要点

大语言模型的预训练损失，就是这个分解下的极大似然。

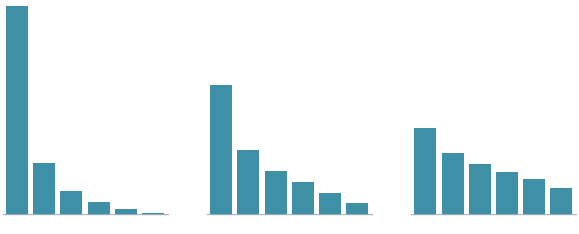
训练并行，生成串行



Teacher forcing：训练时每个位置都读真实前缀；因果 mask 让所有位置在一次前向中并行计算。

Ancestral sampling：生成时抽到的 token 要放回条件里，必须一个一个来。训练见真实前缀、部署见自己的前缀，这个差异叫 exposure bias。

采样温度与截断



同一组 logit（“好、热、冷、不错、晴朗、糟”）在三种温度下的分布

$$p_\tau(v) = \frac{e^{l_v/\tau}}{\sum_u e^{l_u/\tau}}$$

- $\tau < 1$ 更尖，$\tau > 1$ 更平
- top-k / top-p：只保留概率最高的一部分 token，再重新归一化
- 只有 $\tau = 1$ 且不截断时，抽样才严格服从模型自身的分布

玻尔兹曼分布　softmax 就是以 $-l_v$ 为能量、τ 为温度的玻尔兹曼分布。

想一想：每一步都选最可能的 token

同一个问题问两遍，大语言模型的回答不一样：每个 token 都是从 p_τ 中抽出来的。

不想要这种随机性，可以取 $\tau \to 0$：每一步都只选概率最高的 token。

问题

这样生成的回答，是不是最好的回答？

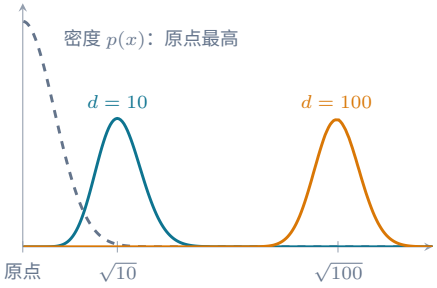
A 是：每一步都是最可能的
B 不是：会出什么问题？

最可能的，并不典型

回到问题　不是。每步都取最可能的 token，文本容易平淡，还会反复绕圈：“我不知道。我不知道。我不知道。……”人写的句子，在模型下的概率也远不是最高的（Holtzman 等，2020）。

典型集　高维分布里，单个最可能的点并不典型：典型样本数量极多，每一个的概率都不高。物理里也一样，300 K 的一杯水不处在基态。

实际解码常用略低于 1 的温度，再加 top-p 截断：既不离谱，也不呆板。



d 维标准高斯。灰虚线：密度沿任一方向的取值（未归一化），原点最高。彩色：样本到原点距离的分布，几乎都落在 $\sqrt{d}$ 附近。半径 r 处的“体积”按 r^{d-1} 增长，压过了密度的下降。每步都取最可能的 token，就是在往“原点”挤

自回归：小结

概率对象

$p_\theta(x) = \prod_t p_\theta(x_t \mid x_{<t})$
显式、精确归一化

训练目标

逐 token 交叉熵
$=$ 极大似然

采样方式

从左到右逐个抽样
温度、top-k、top-p

代价与失效

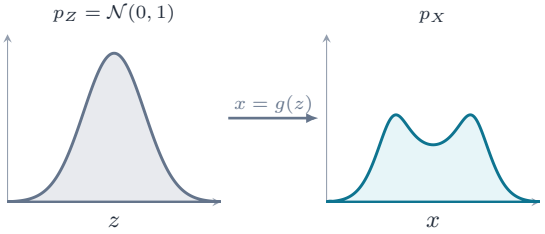
生成串行，延迟随长度增长；exposure bias

要点

自回归是离散序列的首选：似然精确、训练稳定、条件可以随时改变。对连续数据（图像、坐标）没有天然的“下一个”，串行生成也慢，于是需要别的路线。

Normalizing Flow（标准化流）：可逆变换

变量替换：概率质量守恒



$g(z) = z + 0.8\tanh 2z$：中间被拉伸，密度变低；两侧被压缩，密度升高

一维单调变换 $x = g(z)$ 下，小区间里的概率不变：

$$p_X(x)\,|dx| = p_Z(z)\,|dz|$$

$$\Rightarrow\ p_X(x) = p_Z\big(g^{-1}(x)\big)\left|\frac{dg^{-1}}{dx}\right|$$

随机变量函数的密度　这是概率课里的变换公式；Flow 把它当作建模工具：选一个简单的 p_Z，学一个可逆的 g。

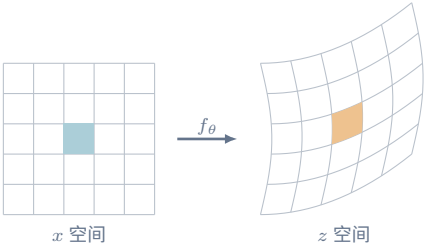
高维：Jacobian 行列式记录体积变化

令 $z = f_\theta(x)$ 可逆可微，

$$\log p_X(x) = \log p_Z\big(f_\theta(x)\big) + \log \left| \det \frac{\partial f_\theta}{\partial x} \right|$$

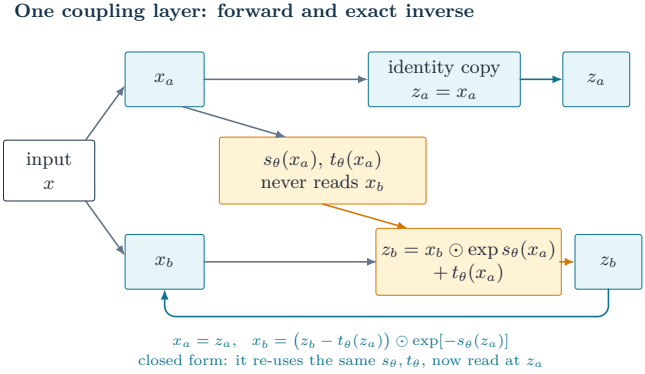
- 训练：极大似然，直接用上式
- 采样：$z \sim \mathcal{N}(0, I)$，再算 $x = f_\theta^{-1}(z)$

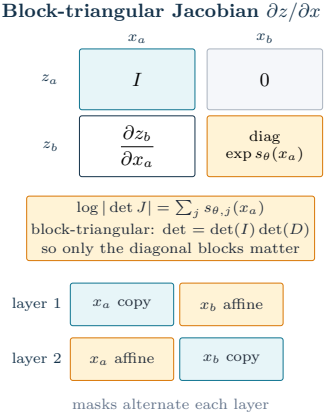
两个障碍　任意网络不一定可逆；$d \times d$ 行列式要 $O(d^3)$，图像的 $d \sim 10^5$。



小方格的面积比 $= |\det J|$

Coupling layer：让 Jacobian 变成三角阵

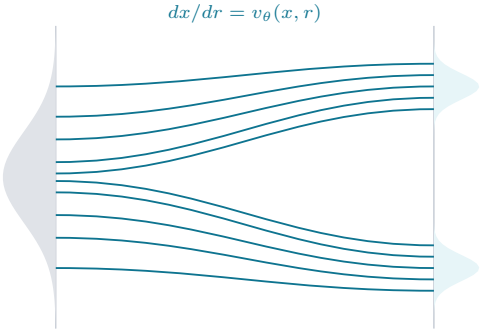




$z_a = x_a$，$z_b = x_b \odot e^{s_\theta(x_a)} + t_\theta(x_a)$。$s_\theta, t_\theta$ 可以是任意网络，它们本身不必可逆。

块三角 Jacobian：$\log|\det J| = \sum_j s_{\theta,j}(x_a)$，代价从 $O(d^3)$ 降到 $O(d)$；相邻层交换 a, b 的划分。

连续极限：连续归一化流（CNF）沿速度场搬运概率



把 $x_{k+1} = x_k + \Delta r\, v_\theta(x_k, r_k)$ 取 $\Delta r \to 0$：

$$\frac{dx}{dr} = v_\theta(x, r), \qquad \frac{d \log p_r(x_r)}{dr} = -\nabla \cdot v_\theta$$

- 速度网络可以自由设计，不再需要特殊结构
- 代价：极大似然训练时，每个样本都要解一次常微分方程（ODE）、沿轨迹积分散度，再让梯度穿过整个求解过程

连续性方程 $\partial_r p_r + \nabla \cdot (p_r v) = 0$：概率像流体一样被搬运，总量守恒。下周的 Flow Matching 保留这个模型，换掉的是训练方式。

Flow：小结

概率对象

可逆映射 $x = f_\theta^{-1}(z)$
变量替换给出精确密度

训练目标

精确负对数似然
$-\log p_Z(f(x)) - \log|\det J|$

采样方式

$z \sim \mathcal{N}(0, I)$ 后运行逆变换
一次前向

代价与失效

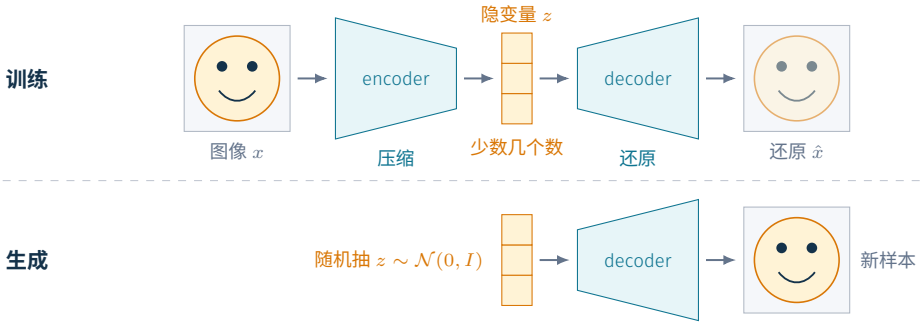
可逆性限制网络结构；高维时样本质量常不如扩散

要点

Flow 同时给出精确似然、可逆编码和直接采样，代价是网络必须同维且可逆。如果允许潜变量维度低于数据、映射不可逆，就得放弃精确似然，这就是 VAE。

VAE（变分自编码器）：隐变量与变分下界

VAE 在做什么：压缩，再还原



要求 1：还原出的 $\hat{x}$ 要像输入 x

要求 2：所有图像的 z 都落在 $\mathcal{N}(0, I)$ 附近；否则生成时抽到的 z 会落进 decoder 没见过的空洞

与普通自编码器的区别　encoder 输出一个小高斯（均值与方差），而不是一个点；生成时只用 decoder。

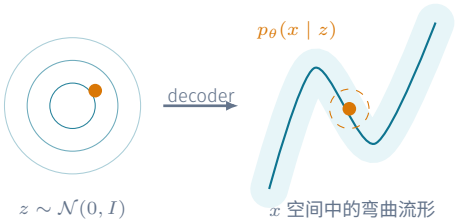
隐变量：观测背后的低维原因

人脸由姿态、光照、表情等少数因素决定。把上一页的“生成”写成概率：

$$p_\theta(x) = \int p(z)\, p_\theta(x \mid z)\, dz, \quad p(z) = \mathcal{N}(0, I)$$

- decoder 读入 z，输出 $p_\theta(x \mid z)$ 的参数
- 非线性 decoder 下积分没有解析解，后验 $p_\theta(z \mid x)$ 同样难算

边缘化与混合分布　每个 z 给出一个分量 $p_\theta(x \mid z)$，$p_\theta(x)$ 是所有分量按 $p(z)$ 加权的叠加。分量有无穷多个，$\log p_\theta(x)$ 无法逐点算出，下一页用证据下界（ELBO）绕开。



左：从先验 $\mathcal{N}(0, I)$ 抽一个 z（橙点）。右：固定这个 z，decoder 在 x 空间给出一个以 $\mu_\theta(z)$ 为中心的小高斯 $p_\theta(x \mid z)$（虚线圈）；所有 z 的小高斯叠在一起，就是浅蓝色的 $p_\theta(x)$

ELBO：把难算的对数似然换成下界

后验算不出来，就用 encoder $q_\phi(z \mid x)$ 去近似它；这就是架构图里负责压缩的那一半：

★ 关键一步

$$\log p_\theta(x) = \underbrace{\mathbb{E}_{q_\phi}\big[\log p_\theta(x \mid z)\big] - \mathrm{KL}\big(q_\phi(z \mid x) \| p(z)\big)}_{\text{ELBO}} + \mathrm{KL}\big(q_\phi(z \mid x) \| p_\theta(z \mid x)\big)$$

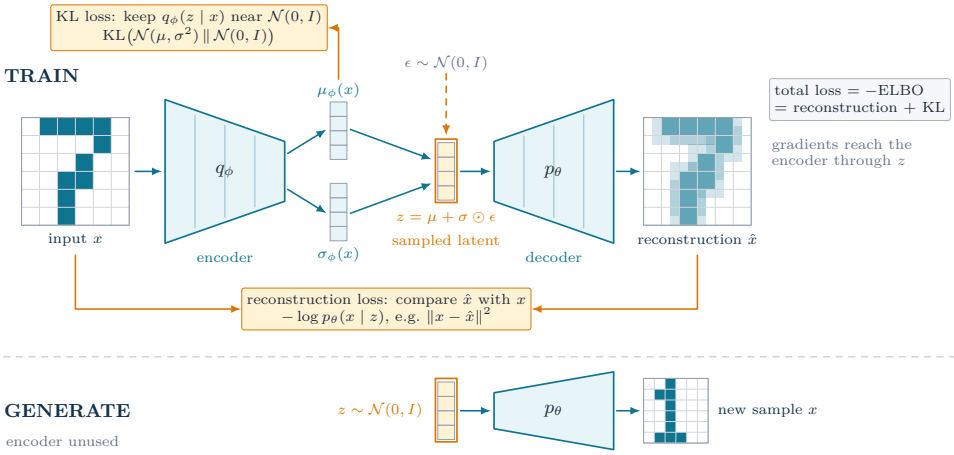
把贝叶斯公式 $p_\theta(z \mid x) = p_\theta(x, z)/p_\theta(x)$ 代入最后一项即可验证。

- 第一项就是要求 1（重构）：已观测的 x 在 decoder 分布下的对数概率
- 第二项就是要求 2：编码分布不要偏离先验，否则从先验采样会落到没训练过的区域



变分推断　间隙含算不出的 $p_\theta(x)$，没法直接算。但固定 θ 时 $\log p_\theta(x)$ 是定值：ELBO 涨多少，间隙就缩多少。所以调 ϕ 抬高 ELBO，就是让 q_ϕ 逼近真实后验，即前面提到的变分推断。

把数学放回网络：VAE 的训练与生成



对角高斯时 $\mathrm{KL}(q\|p) = \frac{1}{2}\sum_j(\mu_j^2 + \sigma_j^2 - \log\sigma_j^2 - 1)$ 有解析式；二值数据的重构项是逐位交叉熵，连续数据常用固定方差高斯，即 MSE。抽样一步写成 $z = \mu + \sigma \odot \epsilon$，梯度就能穿过它（见附录）。

想一想：decoder 太强

ELBO $=$ 重构项 $-\ \mathrm{KL}\big(q_\phi(z \mid x) \| p(z)\big)$。

把 decoder 换成一个很强的自回归模型

$$p_\theta(x \mid z) = \prod_t p_\theta(x_t \mid x_{<t}, z),$$

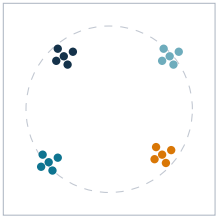
它不看 z，单凭已经生成的像素也能把图像续写得很好。

问题

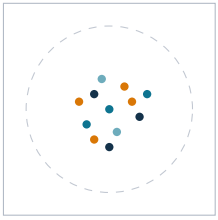
训练之后，隐变量 z 会怎样？

A 携带更多信息：decoder 强，编码也更好
B 不受影响
C 被 decoder 忽略

重构与正则的拉锯



KL 权重过小



KL 权重过大

颜色表示不同类别样本的编码；虚线圈是先验 $\mathcal{N}(0, I)$ 的高概率区

- KL 太弱：编码各自聚成小团，团间是空洞；从先验抽到空洞处，decoder 输出不像样
- KL 太强：所有编码都贴着先验，z 不再携带样本信息，即 posterior collapse
- 高斯 decoder 相当于逐像素 MSE，对多种可能取平均，样本偏模糊

回到问题 C。decoder 不靠 z 也能把重构项做好时，KL 项会把 $q_\phi(z \mid x)$ 一路推回先验 $p(z)$，z 不再携带任何信息，也是 posterior collapse。用 LSTM 生成句子、用 PixelCNN 生成图像的 VAE 都遇到过（Bowman 等，2016；Chen 等，2017）。目标只奖励似然，并不奖励“用上隐变量”。

VAE：小结

概率对象

潜变量模型 $\int p(z)p_\theta(x \mid z)dz$
encoder 近似后验

训练目标

ELBO：重构 $-$ KL
是 $\log p_\theta(x)$ 的下界

采样方式

$z \sim p(z)$，一次 decoder
再从 $p_\theta(x \mid z)$ 抽样

代价与失效

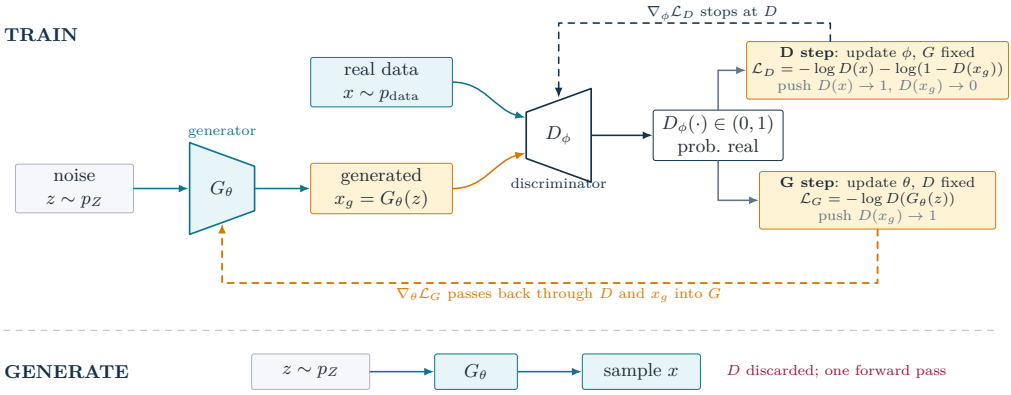
下界有间隙；样本偏模糊；posterior collapse

要点

VAE 用一个可优化的下界换掉难算的积分，并得到有意义的低维表示。今天的图像扩散模型常在 VAE 学出的潜空间里运行。

GAN（生成对抗网络）：放弃似然

生成器与判别器



训练：两步交替。D step 固定 G，让真样本判 1、生成样本判 0；G step 固定 D，让 $D(G(z))$ 变大，梯度穿过 D 回到 G。

生成：丢掉 D，z 经 G 一次前向就是样本。D 只在训练中提供信号，整个模型不给出密度。

让一个分类器来当裁判

生成器 G_θ：$z \sim \mathcal{N}(0, I)$ 一次前向得到 $x = G_\theta(z)$，不给密度。判别器 D_ϕ 判断样本来自数据还是生成器：

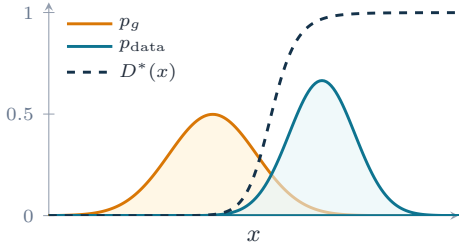
$$\min_{\theta} \max_{\phi} \; \mathbb{E}_{p_{\text{data}}} \log D + \mathbb{E}_z \log(1 - D(G(z)))$$

★ 关键一步

固定 G，最优判别器是密度比：

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$$

代回后生成器在最小化 $2\,\mathrm{JSD}(p_{\text{data}} \| p_g) - \log 4$。



两样本检验与似然比　判别器是一个学出来的检验统计量：它分不清两组样本，两个分布才相同。

想一想：裁判越强越好吗

生成器从头到尾没有见过一张真实图片。它学到的一切，都来自判别器传回的梯度

$$\nabla_\theta \log\bigl(1 - D(G_\theta(z))\bigr).$$

判别器是它唯一的老师。

问题

判别器越强，生成器学得越好吗？

A 越强越好
B 没有影响
C 太强了，生成器反而学不动

GAN 的代价

回到问题 C。判别器太强时，对生成样本一律判“假”，$D(G(z)) \approx 0$，梯度几乎消失：生成器只知道“不行”，不知道往哪里改。两个网络必须势均力敌，而交替更新并不保证收敛。

- 本讲唯一不以似然为目标的路线：没有密度，也报告不了样本的似然
- Mode collapse：生成器只覆盖少数容易骗过判别器的模式，行为接近前面的反向 KL
- 部署时一次前向，速度最快



另一种只用样本的办法：固定核函数，最小化两组样本的最大均值差异（MMD），不需要判别器。

小结

GAN 用一个可学习的检验统计量代替似然：采样最快、样本锐利，代价是无密度、训练不稳定、容易丢模式。

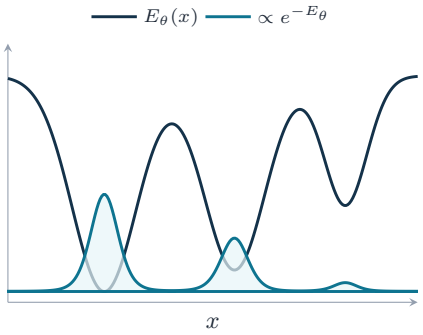
能量模型与 MCMC

用神经网络参数化玻尔兹曼分布

$$p_\theta(x) = \frac{e^{-E_\theta(x)}}{Z_\theta}, \qquad Z_\theta = \int e^{-E_\theta(x)} dx$$

- E_θ 可以是任意标量网络：表达最自由，不需要可逆，也不需要逐步分解
- 物理先验可以直接写进能量
- 代价全部落在 Z_θ 上：它同时出现在密度、采样和训练梯度中

玻尔兹曼分布　前面的形式，只是能量由数据学出来，温度并入 E_θ。



似然梯度：正相位与负相位

★ 关键一步

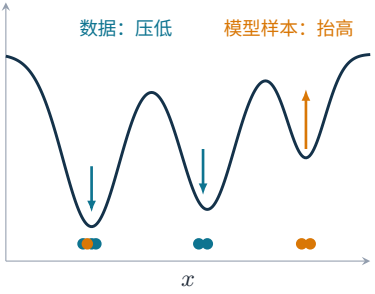
Z_θ 算不出来，它的对数梯度却是一个期望：

$$\nabla_\theta \log Z_\theta = \frac{1}{Z_\theta}\int -\nabla_\theta E_\theta \, e^{-E_\theta}\, dx = -\mathbb{E}_{p_\theta}[\nabla_\theta E_\theta]$$

于是负对数似然的梯度为

$$\nabla_\theta \mathcal{L} = \underbrace{\mathbb{E}_{p_{\text{data}}}[\nabla_\theta E_\theta]}_{\text{正相位}} - \underbrace{\mathbb{E}_{p_\theta}[\nabla_\theta E_\theta]}_{\text{负相位}}$$

- 正相位：压低数据处的能量
- 负相位：抬高模型样本处的能量，防止模型把所有能量都压低



两项平衡时，模型样本与数据分布一致。每一步更新前都要先从当前模型采样。

马尔可夫链蒙特卡洛（MCMC）

构造一条马尔可夫链 $x_0 \to x_1 \to \cdots$，使目标 π 是它的平稳分布；跑得足够久，状态就近似服从 π。

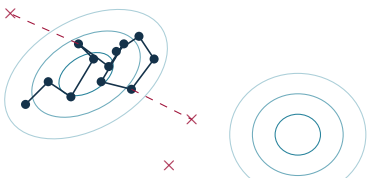
★ 细致平衡

若转移核满足 $\pi(x)K(x' \mid x) = \pi(x')K(x \mid x')$，对 x 求和即得 $\sum_x \pi(x)K(x' \mid x) = \pi(x')$，$\pi$ 是平稳分布。

Metropolis–Hastings（MH）：从 $q(x' \mid x)$ 提议，以

$$a = \min\Big\{1,\ \frac{\tilde{\pi}(x')\, q(x \mid x')}{\tilde{\pi}(x)\, q(x' \mid x)}\Big\}$$

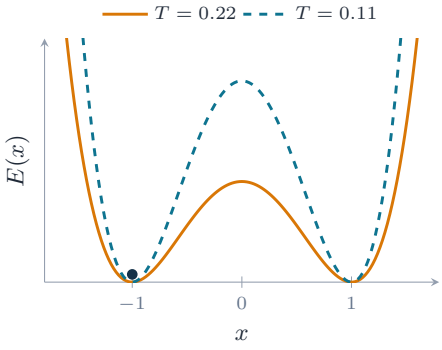
接受，否则留在原地。只用到比值，Z 被约掉。



链在一个模式内游走；× 是被拒绝的提议。另一模式很难到达

马尔可夫链与平稳分布　遍历性保证极限存在；收敛快慢由混合时间决定。

想一想：降温之后



双势阱 $E(x) = (x^2 - 1)^2 / T$，从左谷出发跑一条 MCMC 链（下一页的 Langevin 动力学，步长 $\eta = 0.01$）。$T = 0.22$ 时，链平均约 5000 步跨到右谷一次。

问题

温度降一半（$T = 0.11$，势垒高一倍），平均要多少步？

A 约 1 万步
B 约 2 万步
C 远不止

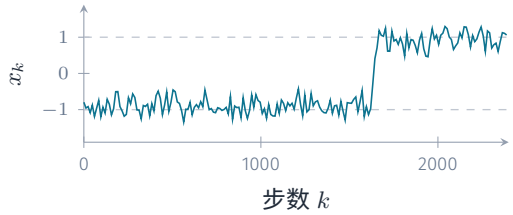
Langevin 动力学：沿梯度下坡，再加热噪声

连续变量时，用能量梯度构造提议：

$$x_{k+1} = x_k - \frac{\eta}{2}\nabla_x E(x_k) + \sqrt{\eta}\,\xi_k$$

- 下坡项推向低能区，噪声 $\xi_k \sim \mathcal{N}(0, I)$ 让样本有机会翻越势垒
- 连续极限以 e^{-E} 为平稳分布；有限步长的偏差可用 MH 校正
- 混合慢：势垒高时，链要很久才跨到另一个谷

布朗运动　$dx = -\frac{1}{2}\nabla E\,dt + dW_t$；下周的扩散模型用同一类随机微分方程。



双势阱 $E = (x^2-1)^2/T$ 中的一条 Langevin 链：长时间停在一个谷里，偶尔跃迁

回到问题　C。$\Delta E = 1/T$ 从 4.5 升到 9.1，按 Arrhenius 定律 $\tau \propto e^{\Delta E}$，指数项放大约 90 倍；计入其他因子，实测约 21 万步，慢 40 多倍。对付势垒要升温、退火，下周再见。

训练能量模型的实际做法

每次参数更新都要负相位样本，而充分混合的链太贵。常用有偏但便宜的近似：

- **CD-k**（对比散度）：从数据点出发只跑 k 步，用短链终点作负样本；只修正数据附近的错误
- **持续链**：保存上一轮的链状态，下一轮接着跑；不必每次重新预热，但参数在变，链在追一个移动的目标

推理时同样要跑链：生成一个样本需要成百上千步。

概率对象	$p_\theta \propto e^{-E_\theta}$ 最灵活，未归一化
训练目标	正相位 − 负相位 （极大似然的梯度）
采样方式	MCMC / Langevin 多步迭代
代价与失效	负相位昂贵；混合慢；样本有偏

Score（得分函数）：一个与 Z 无关的量

$$s(x) = \nabla_x \log p(x) = -\nabla_x E(x)$$

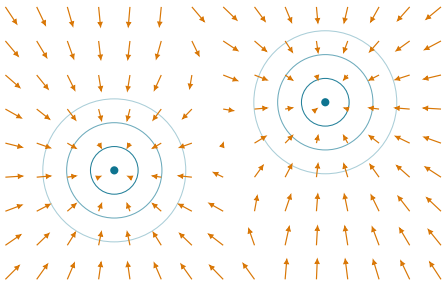
Z 对 x 是常数，求梯度后消失。score 是指向密度上升最快方向的向量场。

★ score matching

用 Fisher 散度比较两个分布：$D_F(p\|q) = \frac{1}{2}\mathbb{E}_p\|\nabla \log p - \nabla \log q\|^2$，它只看两者的 score 是否处处一致。取 $q = p_\theta$，分部积分去掉未知的 $\nabla \log p_{\text{data}}$：

$$D_F(p_{\text{data}}\|p_\theta) = \mathbb{E}_{p_{\text{data}}}\left[\frac{1}{2}\|s_\theta\|^2 + \nabla \cdot s_\theta\right] + C$$

只用数据样本，不需要负样本。



双峰分布的 score 场：箭头指向附近的模式

第一周小结

	概率对象	训练目标	采样	主要代价
自回归	$\prod_t p(x_t \mid x_{<t})$	极大似然（交叉熵）	逐个抽样	串行
Flow	可逆变换 + Jacobian	精确极大似然	逆变换一次	结构受限
VAE	潜变量的连续混合	ELBO（下界）	decoder 一次	下界间隙、模糊
GAN	隐式分布	对抗博弈（JSD）	生成器一次	无密度、丢模式
能量模型	e^{-E_θ}/Z_θ	正相位 − 负相位	MCMC 多步	混合慢

带走的几件事

1. 极大似然是前向 KL；从能量出发的变分自由能是反向 KL。前向覆盖模式，反向抓住模式
2. 归一化常数 Z 是高维概率建模的核心难点，各类模型的区别就在怎样处理它
3. 能量模型最灵活，却被采样拖累；score 绕开了 Z。如果在每个噪声水平上都学一个 score 呢？这就是下周的扩散模型

附录

附录：怎样对“抽样”求梯度

ELBO 里有 $\mathbb{E}_{z\sim q_\phi}[\cdot]$，而抽样分布本身含有待训练的 ϕ。两条路径：

	重参数化	score-function
写法	$z=\mu_\phi+\sigma_\phi\odot\epsilon$，$\epsilon\sim\mathcal{N}(0,I)$	$\nabla_\phi\mathbb{E}_{q_\phi}[h]=\mathbb{E}_{q_\phi}\left[h\,\nabla_\phi\log q_\phi(z)\right]$
梯度从哪里来	沿 $\epsilon\to z\to h$ 的计算图回传	用得分 h 加权对数概率的梯度
要求	抽样可写成可微变换	只需 $\log q_\phi$ 可微；z 可以离散
方差	通常较低	通常较高，常减去一个基线
用在哪里	VAE、GAN	强化学习、大模型 RLHF（下周）

正态随机变量的标准化 $z\sim\mathcal{N}(\mu,\sigma^2)$ 等价于 $z=\mu+\sigma\epsilon$。把随机性挪到与参数无关的 ϵ 上，z 就对 μ,σ 可微。